Universidad Rafael Landivar
Facultad de ingeniería

Ciencia de Datos

Ing. Max Cerna



Fase 1 Proyecto

José Rodrigo Rosales Mirón – 1143323

Paula Ximena Navarro Ruano – 1006323

Eddy Paolo Marroquín Montenegro - 1146822

Guatemala 23 de septiembre de 2026

1. Resumen de la fase

En esta fase construimos el flujo de datos de una red metropolitana que integra cuatro operadores de transporte: Transmetro, Transurbano, MetroRiel y Aerómetro. La meta fue recibir datos por diferentes vías, conservar una capa Bronze trazable, llevar la información a Staging, limpiar y homologar en Silver, construir un modelo dimensional en Gold y finalmente orquestar todo con Prefect. Además, comprobamos la idempotencia ejecutando el pipeline completo dos veces y comparando los resultados. Durante todo el proceso fuimos validando conteos y guardando evidencia de los resultados finales, no solamente de la ejecución de comandos.

Indicador	Resultado
Registros totales inventariados	1,730,184
Fuentes de datos	9 archivos
Capa Bronze	Parquet particionado por fecha de ingesta
Eventos CDC	31,050
Registros en cuarentena	9,707
Versiones históricas SCD Tipo 2	28,844
Usuarios Gold	70,380
Abordajes Gold	1,393,448
Viajes MetroRiel Gold	295,511
Pruebas dbt globales	55/55 aprobadas
Idempotencia	Validada: mismas métricas en 2 corridas

2. Organización del documento

- Preparación e inventario de fuentes
- Arquitectura, decisiones de ingesta y capa Bronze
- Staging y procesamiento CDC
- Transformaciones Silver y calidad
- Modelo dimensional Gold, matriz del bus y DDL
- Orquestación con Prefect
- Prueba de idempotencia
- Conclusiones y resumen de evidencias

3. Preparación e inventario de fuentes

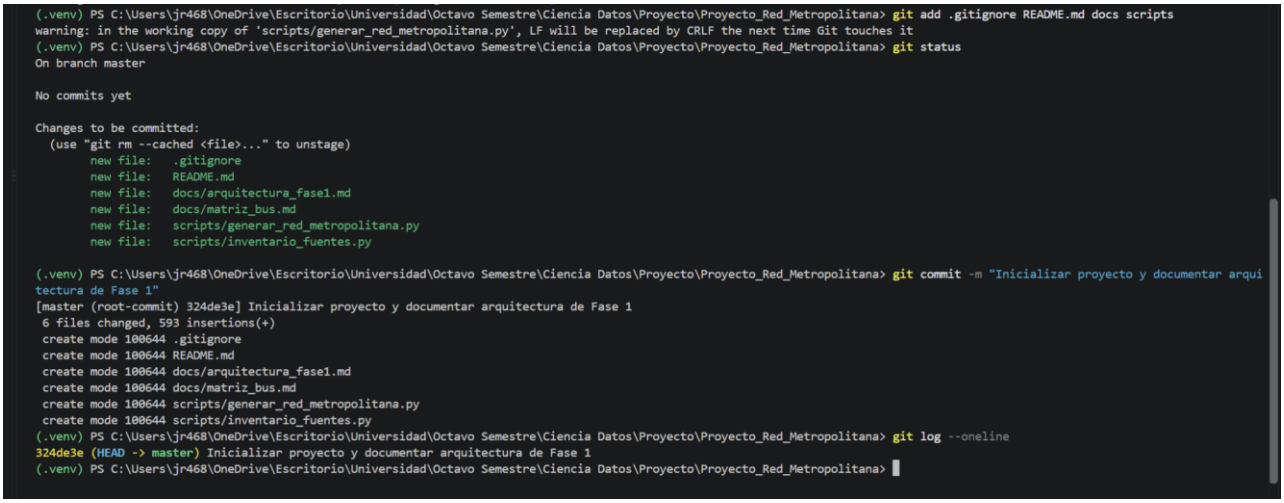
Primero organizamos el proyecto y revisamos qué archivos venían en el ZIP proporcionado. Antes de transformar algo hicimos un inventario para saber cuántos registros tenía cada fuente, qué formato utilizaba y cuál era su función dentro de la solución. Esto nos permitió definir desde el inicio qué fuentes se trabajarían por batch, cuáles simularían streaming y cuál representaba CDC.

Fuente	Tipo	Registros
tm_estaciones.csv	Catálogo Transmetro	104
tu_paradas.csv	Catálogo Transurbano	328
mr_estaciones.csv	Catálogo MetroRiel	22
am_estaciones.csv	Catálogo Aerómetro	14
transmetro_validaciones.csv	Operación / Streaming	363,221
transurbano_transacciones.csv	Operación / Batch	832,791
metroriel_viajes.jsonl	Operación / Batch	299,100
aerometro_boardings.csv	Operación / Streaming	203,554
cdc_padron_usuarios.csv	CDC padrón	31,050

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> python scripts/inventario_fuentes.py
================================================================================
INVENTARIO INICIAL DE FUENTES - RED METROPOLITANA
================================================================================
ARCHIVO                          FORMATO   TIPO                      REGISTROS   TAMAÑO MB
--------------------------------------------------------------------------------
tm_estaciones.csv                CSV       Catálogo Transmetro             104        0.01
tu_paradas.csv                   CSV       Catálogo Transurbano            328        0.01
mr_estaciones.csv                CSV       Catálogo MetroRiel               22        0.00
am_estaciones.csv                CSV       Catálogo Aerómetro               14        0.00
transmetro_validaciones.csv      CSV       Operación Transmetro         363,221       22.93
transurbano_transacciones.csv    CSV       Operación Transurbano        832,791       41.13
metroriel_viajes.jsonl           JSONL     Operación MetroRiel          299,100       52.75
aerometro_boardings.csv          CSV       Operación Aerómetro          203,554       11.56
cdc_padron_usuarios.csv          CSV       CDC padrón usuarios           31,050        2.05
--------------------------------------------------------------------------------
TOTAL                                                                1,730,184      130.44
================================================================================
Inventario completado correctamente.
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana>
```

Evidencia 1 - Inventario de las nueve fuentes con un total de 1,730,184 registros.

También trabajamos con un repositorio Git local desde el inicio. Fuimos haciendo commits por bloques funcionales para dejar trazabilidad de la evolución de la arquitectura, Staging, Silver, Gold y orquestación.



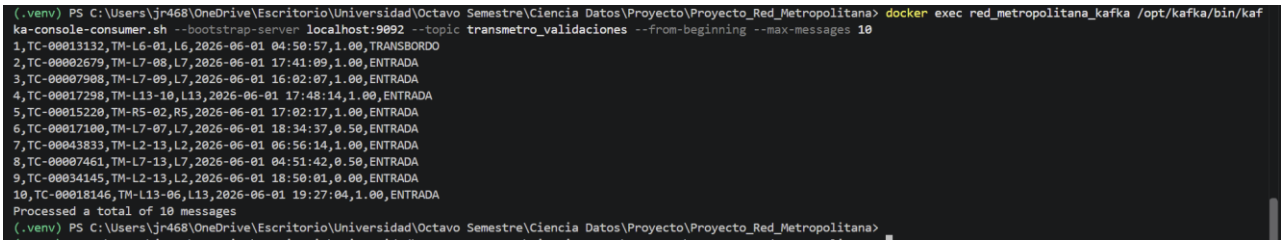
Evidencia 2 - Primer commit con la estructura base, documentación y scripts del proyecto.

4. Arquitectura e ingesta Bronze

La capa Bronze quedó como la copia técnica y trazable de las fuentes. Para los datos de operación de Transmetro y Aerómetro utilizamos Kafka como mecanismo de streaming. Los mensajes se publicaron en topics separados y luego fueron consumidos hacia archivos Parquet. Para los catálogos, Transurbano, MetroRiel y CDC utilizamos carga batch. La idea fue conservar el dato crudo y agregar metadatos de ingesta para poder reconstruir las capas posteriores sin perder el origen.

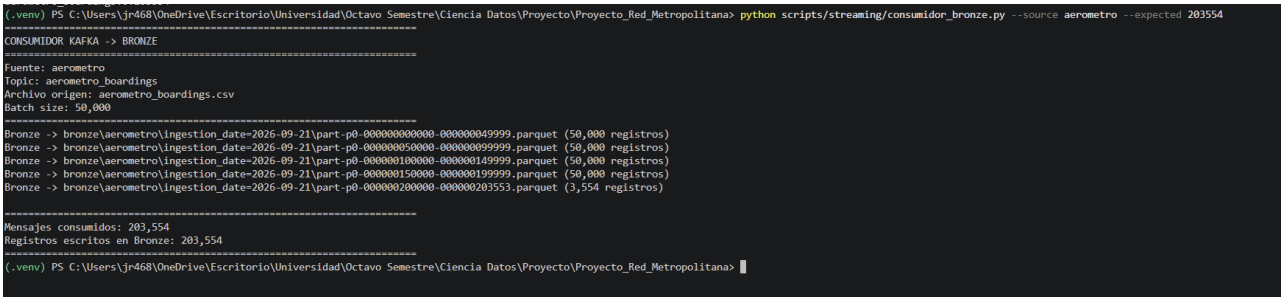
4.1 Streaming con Kafka

Comprobamos el flujo productor-consumidor antes de cargar todos los registros. En la prueba de Transmetro se publicaron y consumieron mensajes del topic correspondiente, verificando que el contenido llegaba sin alteraciones.



Evidencia 3 - Consumo de mensajes del topic de Transmetro desde Kafka.

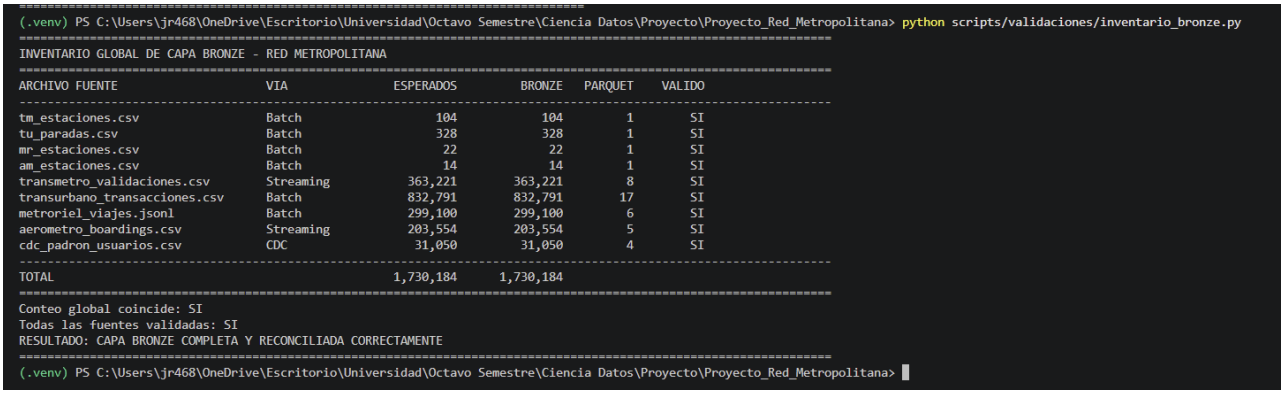
Después ejecutamos la carga completa. En Aerómetro, por ejemplo, se consumieron 203,554 mensajes y se escribieron en cinco archivos Parquet, lo que confirmó que el streaming se podía materializar de forma controlada en Bronze.



Evidencia 4 - Consumidor Kafka de Aerómetro escribiendo 203,554 registros a Bronze.

4.2 Reconciliación global de Bronze

Una vez terminadas las tres vías de ingesta, corrimos un inventario global de Bronze. El resultado mostró que los nueve archivos fuente quedaron representados y que el total esperado coincidía exactamente con el total almacenado: 1,730,184 registros. Esta validación fue importante porque a partir de aquí Bronze se convirtió en el punto estable para reconstruir el resto del pipeline.



Evidencia 5 - Reconciliación global de Bronze: 1,730,184 registros esperados y encontrados.

4.3 Decisiones de arquitectura de ingesta

Además de definir las vías de entrada, dejamos documentadas dos decisiones que afectan directamente la arquitectura: cómo procesar Transurbano y dónde conservar Bronze. Las tomamos buscando respetar la forma real en que venían los datos y evitar agregar complejidad que no aportaba a la práctica.

Decisión	Criterio utilizado
Transurbano por batch	La fuente se entregó como un archivo completo de 832,791 transacciones. Procesarlo por lotes permitió validar conteos, repetir la carga de forma controlada y demostrar idempotencia sin simular un streaming que no existía en el origen.
Bronze en lake local (Parquet)	Bronze se dejó fuera del warehouse para conservar una copia cruda, trazable y económica. Los archivos Parquet se particionaron por fecha de ingesta y PostgreSQL se utilizó a partir de Staging, donde ya era necesario consultar y transformar datos relacionales.

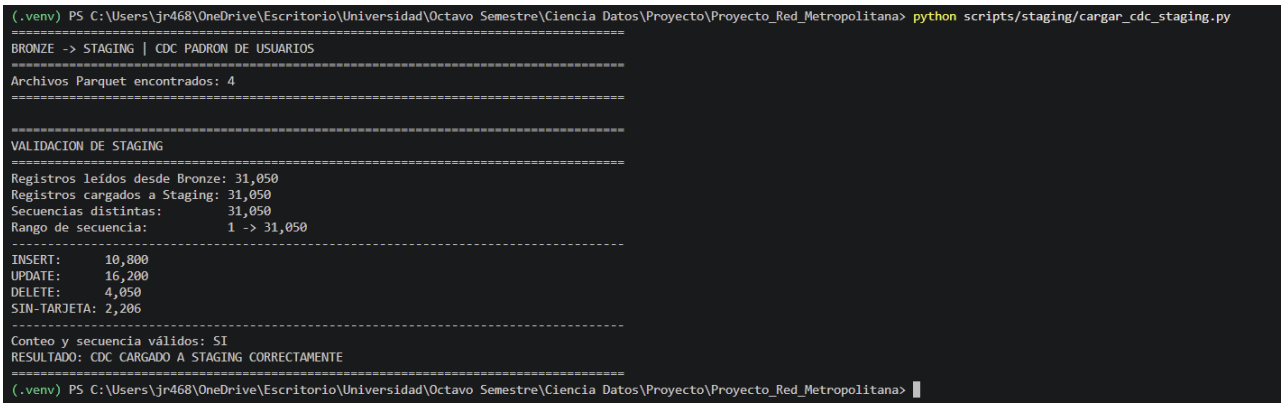
Con esto, Bronze funciona como la zona de aterrizaje reproducible del pipeline y el warehouse queda reservado para Staging, Silver y Gold, donde sí se necesita estructura y capacidad de consulta.

5. Staging y procesamiento CDC

En Staging llevamos la información desde Parquet a PostgreSQL. Separamos operaciones, catálogos y CDC para que cada grupo pudiera validarse de manera independiente. En el padrón mantuvimos el orden de secuencia de los eventos, porque los INSERT, UPDATE y DELETE deben aplicarse en el orden en que fueron generados.

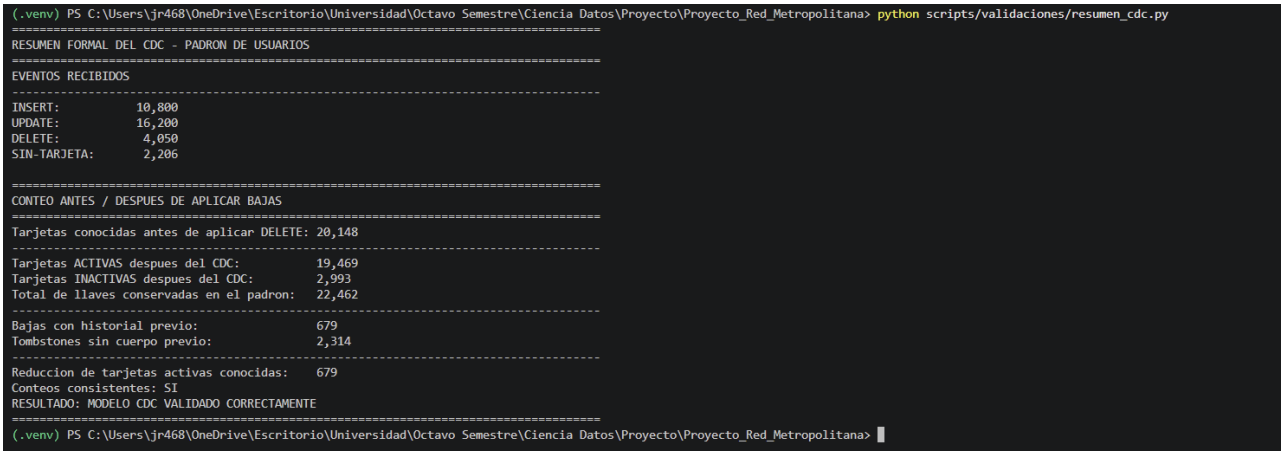
5.1 CDC del padrón

El archivo CDC contenía 31,050 eventos: 10,800 INSERT, 16,200 UPDATE, 4,050 DELETE y 2,206 filas sin tarjeta. La carga a Staging conservó el total y el rango completo de secuencias.



Evidencia 6 - Carga de 31,050 eventos CDC a Staging y validación de la secuencia.

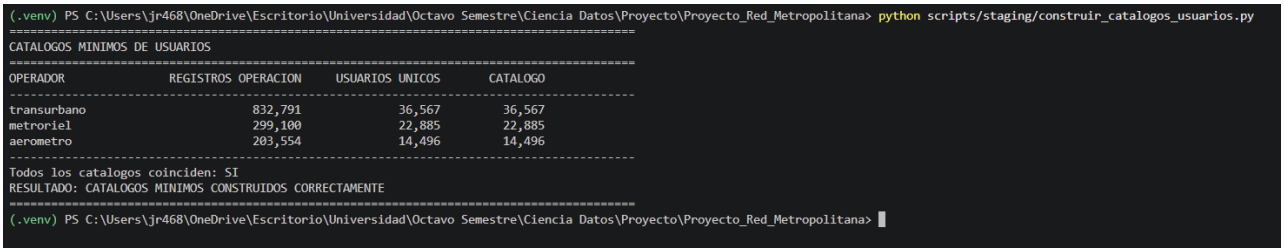
Al aplicar los eventos secuencialmente obtuvimos 22,462 tarjetas vigentes: 19,469 activas y 2,993 inactivas. También se conservaron los tombstones de DELETE cuando no existía cuerpo previo, en lugar de ocultar esas bajas.



Evidencia 7 - Resumen formal del CDC con tarjetas activas, inactivas, bajas y tombstones.

5.2 Catálogos mínimos de usuarios

Para las operaciones de Transurbano, MetroRiel y Aerómetro construimos catálogos mínimos de usuarios a partir de las llaves encontradas. Estos catálogos se usaron posteriormente para apoyar la estrategia de identidad aproximada.



Evidencia 8 - Catálogos mínimos de usuarios construidos a partir de las operaciones.

5.3 Conteos antes y después del CDC

Para dejar clara la aplicación de los borrados, resumimos el estado del padrón antes y después de procesar los eventos DELETE. El archivo disponible para CDC fue cdc_padron_usuarios.csv y sobre esa secuencia se aplicaron INSERT, UPDATE y DELETE en el orden definido por seq.

Indicador CDC	Conteo
Eventos recibidos	31,050
Tarjetas conocidas antes de aplicar DELETE	20,148
Bajas con historial previo	679
Tombstones sin cuerpo previo	2,314
Llaves conservadas en el padrón final	22,462
Tarjetas activas al final	19,469
Tarjetas inactivas al final	2,993

5.3.1 Usuarios únicos por operador

También contamos las llaves únicas observadas por operador antes de construir la identidad integrada. Estos conteos representan identificadores de fuente, no personas confirmadas.

Operador	Usuarios / llaves únicas
Transmetro	43,255
Transurbano	36,567
MetroRiel	22,885
Aerómetro	14,496

En el padrón CDC, además, se identificaron 17,432 llaves con formato TM. Ese valor corresponde al subconjunto del padrón con ese formato y no debe confundirse con las 43,255 llaves únicas observadas en la operación de Transmetro.

6. Capa Silver: normalización, calidad e identidad

Silver fue la capa donde convertimos el dato a un formato más analítico. Normalizamos fechas, montos y zonas; separamos registros válidos de los que no cumplían las reglas de calidad; construimos una estrategia aproximada de identidad y mantuvimos el historial del padrón con SCD Tipo 2.

6.1 Reglas de calidad y cuarentena

Sistema	Regla	Registros	Porcentaje de la fuente
Transmetro	DUPLICADO_TORNIQUETE	1,115	0.3070 %
Transurbano	COD_PARADA_NULO	4,189	0.5030 %
Transurbano	FECHA_FUTURA	817	0.0981 %
MetroRiel	VIAJE_SIN_SALIDA	3,589	1.1999 %

Los registros malos no se eliminaron: se enviaron a tablas de cuarentena con el motivo correspondiente. En Transurbano tres filas incumplían dos reglas al mismo tiempo, por lo que la suma de reglas es 9,710 pero la cuarentena física contiene 9,707 registros únicos.

```
Tarjetas distintas en padron:    22,462
Tarjetas ACTIVAS:                19,469
Tarjetas INACTIVAS:              2,993
--------------------------------------------------------------------------------
Tarjetas con cuerpo conocido:    20,148
Bajas con historial previo:      679
Tombstones sin cuerpo previo:    2,314
--------------------------------------------------------------------------------
FORMATOS DE LLAVE ENCONTRADOS:
  FORMATO_MR           992
  FORMATO_TM        17,432
  FORMATO_TU         4,038
--------------------------------------------------------------------------------
Conteo del padron consistente: SI
RESULTADO: CDC APLICADO CORRECTAMENTE
================================================================================

01:18:50.522 | INFO    | Task run 'Aplicar CDC del padrón-c06' - APLICAR CDC AL PADRÓN completado en 12.79 segundos.
01:18:50.524 | INFO    | Task run 'Aplicar CDC del padrón-c06' - Finished in state Completed()
01:18:50.526 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - ================================================================================
01:18:50.528 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - CATÁLOGOS MÍNIMOS DE USUARIOS
01:18:50.528 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - ================================================================================
01:18:56.599 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - ================================================================================
CATALOGOS MINIMOS DE USUARIOS
================================================================================
OPERADOR              REGISTROS OPERACION     USUARIOS UNICOS       CATALOGO
--------------------------------------------------------------------------------
transurbano                       832,791             36,567         36,567
metroriel                         299,100             22,885         22,885
aerometro                         203,554             14,496         14,496
--------------------------------------------------------------------------------
Todos los catalogos coinciden: SI
RESULTADO: CATALOGOS MINIMOS CONSTRUIDOS CORRECTAMENTE
================================================================================

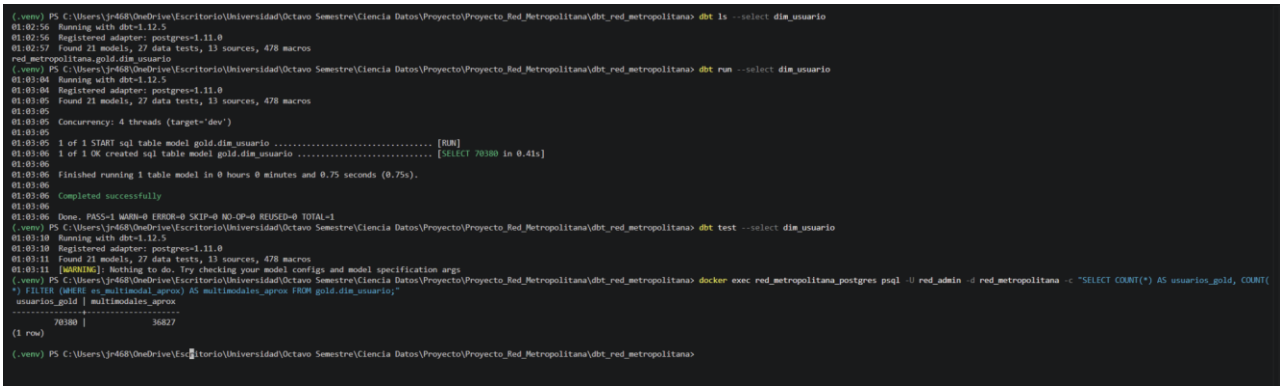
01:18:56.599 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - CATÁLOGOS MÍNIMOS DE USUARIOS completado en 6.07 segundos.
01:18:56.602 | INFO    | Task run 'Construir catálogos de usuarios-3b0' - Finished in state Completed()
01:18:56.606 | INFO    | Task run 'Cargar operaciones a Staging-946' - ================================================================================
01:18:56.606 | INFO    | Task run 'Cargar operaciones a Staging-946' - BRONZE -> STAGING | OPERACIONES
01:18:56.606 | INFO    | Task run 'Cargar operaciones a Staging-946' - ================================================================================
01:19:49.702 | INFO    | Task run 'Cargar operaciones a Staging-946' - ================================================================================
BRONZE -> STAGING | FUENTES OPERATIVAS
================================================================================
Transmetro cargado:  363,221
Transurbano cargado: 832,791
MetroRiel cargado:   299,100
Aerometro cargado:   203,554
--------------------------------------------------------------------------------
FUENTE                      BRONZE        STAGING      VALIDO
--------------------------------------------------------------------------------
Transmetro                 363,221        363,221          SI
Transurbano                832,791        832,791          SI
MetroRiel                  299,100        299,100          SI
Aerometro                  203,554        203,554          SI
--------------------------------------------------------------------------------
Todas las fuentes coinciden: SI
RESULTADO: OPERACIONES CARGADAS A STAGING CORRECTAMENTE
================================================================================

01:19:49.704 | INFO    | Task run 'Cargar operaciones a Staging-946' - BRONZE -> STAGING | OPERACIONES completado en 53.10 segundos.
01:19:49.706 | INFO    | Task run 'Cargar operaciones a Staging-946' - Finished in state Completed()
01:19:49.710 | INFO    | Task run 'Cargar catálogos a Staging-b76' - ================================================================================
01:19:49.710 | INFO    | Task run 'Cargar catálogos a Staging-b76' - BRONZE -> STAGING | CATÁLOGOS
01:19:49.710 | INFO    | Task run 'Cargar catálogos a Staging-b76' - ================================================================================
01:19:51.379 | INFO    | Task run 'Cargar catálogos a Staging-b76' - ================================================================================
BRONZE -> STAGING | CATALOGOS DE TRANSPORTE
================================================================================
CATALOGO                  ESPERADO        BRONZE        STAGING      VALIDO
--------------------------------------------------------------------------------
TM estaciones                  104           104           104          SI
TU paradas                     328           328           328          SI
MR estaciones                   22            22            22          SI
```

Evidencia 9 - Resumen global de calidad de Silver y conteo por regla de rechazo.

6.2 Identidad aproximada

No existía una tabla maestra que relacionara las tarjetas de los cuatro operadores. Por eso trabajamos con una identidad aproximada: para Transmetro, Transurbano y MetroRiel utilizamos el componente numérico de la llave; Aerómetro se dejó separado porque su identificador es un hash. La salida produjo 117,203 llaves de fuente y 36,827 identidades aproximadas que aparecen en más de un sistema.



Evidencia 10 - Conteos de llaves por sistema e identidades multimodales aproximadas.

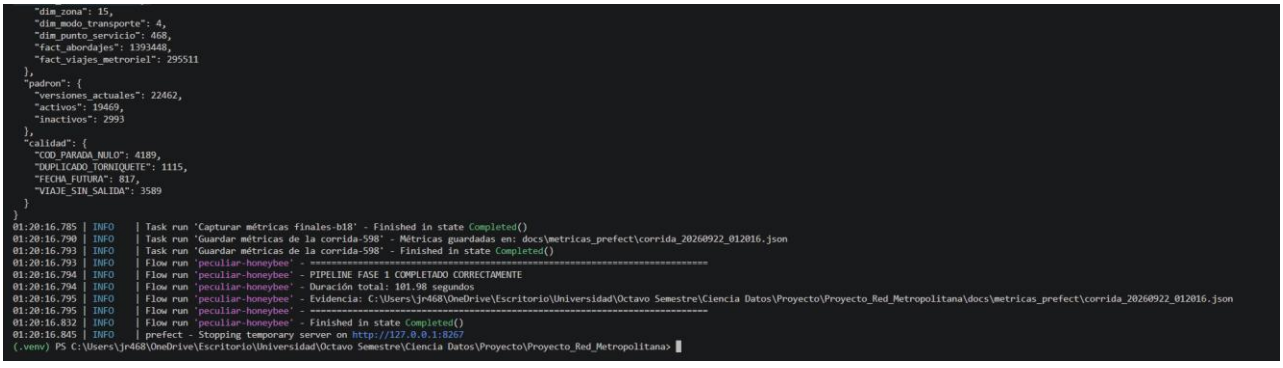
6.2.1 Supuestos y límites de la estrategia de identidad

La integración de usuarios se diseñó de forma conservadora porque no existe una llave maestra compartida entre los operadores. Por eso los resultados de multimodalidad se interpretan como aproximaciones para análisis y no como identificación definitiva de una persona.

- Para Transmetro, Transurbano y MetroRiel se asumió que el componente numérico comparable de la llave puede utilizarse como señal de coincidencia.
- Una coincidencia numérica no demuestra por sí sola que dos tarjetas pertenezcan a la misma persona; por eso el modelo mantiene la etiqueta de identidad aproximada.
- Aerómetro se mantiene separado porque su user_hash no se puede conciliar de forma confiable con las llaves de los otros sistemas.
- Las 36,827 identidades multimodales son coincidencias aproximadas y no deben utilizarse como prueba de identidad individual.
- Para una integración real sería necesaria una llave maestra, un proceso institucional de conciliación o un mecanismo de identidad compartido entre operadores.

6.3 SCD Tipo 2 del padrón

El padrón no se dejó únicamente con el estado final. Construimos un modelo SCD Tipo 2 para conservar cada versión histórica. Se generaron 28,844 versiones para 22,462 tarjetas, manteniendo exactamente una versión actual por tarjeta. Las cinco pruebas dbt del modelo pasaron sin errores.



Evidencia 11 - SCD Tipo 2: 28,844 versiones históricas, 22,462 versiones actuales y 5/5 pruebas aprobadas.

7. Capa Gold y modelo dimensional

Para Gold definimos dos granos de negocio. Los abordajes de Transmetro, Transurbano y Aerómetro se modelaron como una fila por abordaje, mientras que MetroRiel se trabajó como una fila por viaje completo porque sí contiene origen, destino, entrada, salida y duración. Esta separación evita inventar destinos para fuentes que no los registran.

Objeto Gold	Filas
dim_modo_transporte	4
dim_punto_servicio	468
dim_tiempo	45
dim_usuario	70,380
dim_zona	15
fact_abordajes	1,393,448
fact_viajes_metroriel	295,511

7.1 Diseño dimensional: matriz del bus, grano y medidas

Antes de construir las tablas Gold definimos el grano de cada proceso y las dimensiones que podían compartirse. Esta decisión fue importante porque no todos los operadores registran el mismo nivel de detalle: Transmetro, Transurbano y Aerómetro registran abordajes, mientras MetroRiel sí permite representar un viaje completo.

7.1.1 Matriz del bus

Proceso de negocio	Usuario	Tiempo	Zona	Modo	Punto servicio	Línea/Ruta	Origen	Destino
Abordajes Transmetro	X	X	X	X	X	X		
Abordajes Transurbano	X	X	X	X	X	X		
Abordajes Aerómetro	X	X	X	X	X	X		
Viajes MetroRiel	X	X	X	X			X	X

7.1.2 Grano de las tablas de hechos

Tabla de hechos	Grano
fact_abordajes	Una fila por abordaje válido de Transmetro, Transurbano o Aerómetro.
fact_viajes_metroriel	Una fila por viaje completo válido de MetroRiel, con origen, destino, entrada y salida.

7.1.3 Clasificación de medidas

Tabla	Medida	Clasificación	Uso
fact_abordajes	cantidad_abordajes	Aditiva	Se puede sumar por cualquier dimensión.
fact_abordajes	tarifa_gtq	Aditiva	Permite obtener ingresos acumulados por tiempo, zona, modo o punto.
fact_viajes_metroriel	cantidad_viajes	Aditiva	Se puede sumar por cualquier dimensión.
fact_viajes_metroriel	tarifa_gtq	Aditiva	Permite acumular el monto de los viajes.
fact_viajes_metroriel	duracion_segundos	Aditiva como base numérica	Se conserva por viaje y se usa principalmente para promedio, mínimo y máximo; también puede acumularse si el análisis lo requiere.

El diagrama lógico siguiente muestra cómo las dimensiones conformadas se reutilizan entre ambas tablas de hechos. En MetroRiel, dim_punto_servicio y dim_zona actúan con roles de origen y destino.

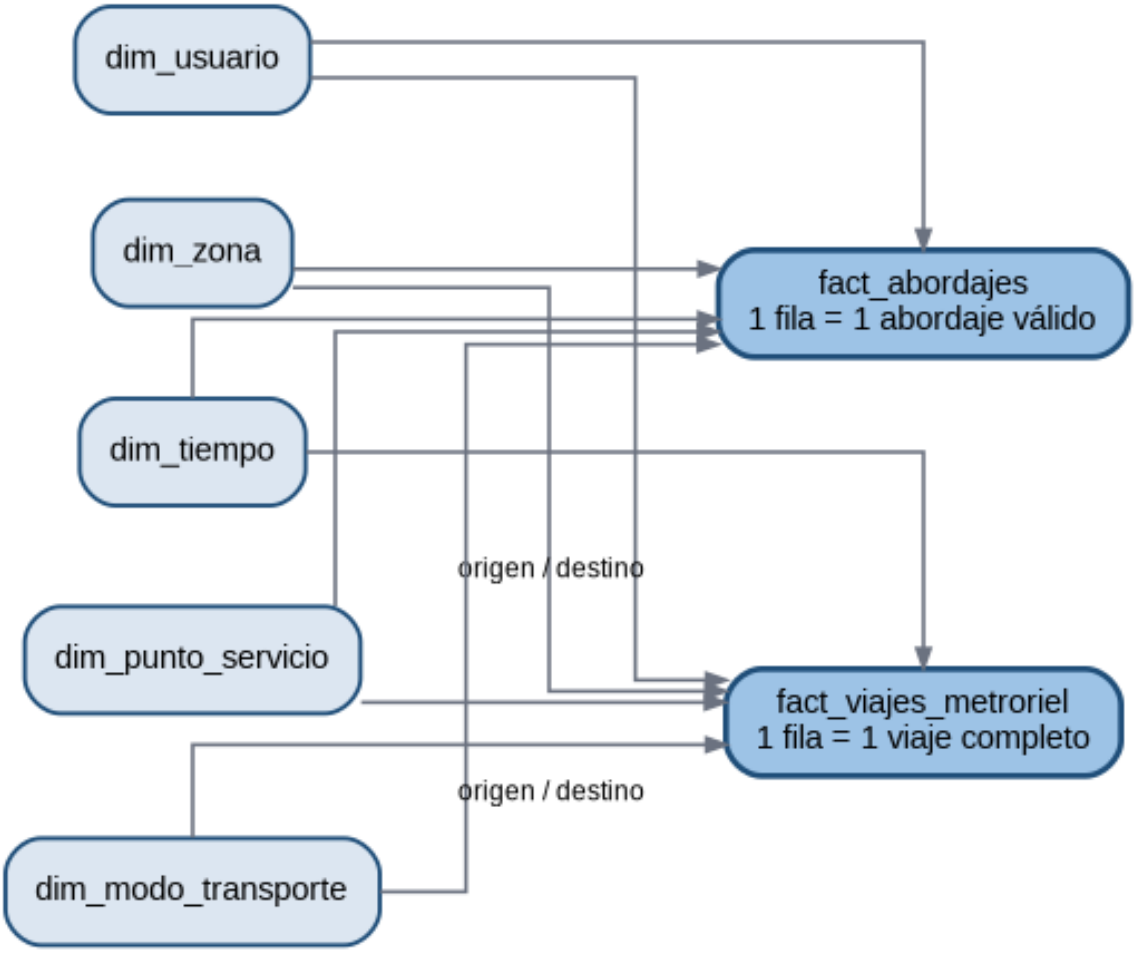


Diagrama lógico del modelo dimensional Gold.

7.2 Dimensión tiempo

La dimensión tiempo se generó de forma automática con el rango de fechas real de las operaciones: del 1 de junio al 15 de julio de 2026. Se incluyeron año, trimestre, mes, día y fin de semana, y se validaron llaves y fechas con pruebas dbt.

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\dbt_red_metropolitana> docker exec red_metropolitana_postgres psql -U red_admin -d red_metropolitana -c "SELECT * FROM gold.dim_tiempo ORDER BY fecha LIMIT 15;"
 tiempo_key |   fecha    | anio | trimestre | mes_numero | mes_nombre | dia_mes | dia_semana_numero | dia_semana_nombre | es_fin_semana
------------+------------+------+-----------+------------+------------+---------+-------------------+-------------------+---------------
   20260601 | 2026-06-01 | 2026 |         2 |          6 | Junio      |       1 |                 1 | Lunes             | f
   20260602 | 2026-06-02 | 2026 |         2 |          6 | Junio      |       2 |                 2 | Martes            | f
   20260603 | 2026-06-03 | 2026 |         2 |          6 | Junio      |       3 |                 3 | Miercoles         | f
   20260604 | 2026-06-04 | 2026 |         2 |          6 | Junio      |       4 |                 4 | Jueves            | f
   20260605 | 2026-06-05 | 2026 |         2 |          6 | Junio      |       5 |                 5 | Viernes           | f
   20260606 | 2026-06-06 | 2026 |         2 |          6 | Junio      |       6 |                 6 | Sabado            | t
   20260607 | 2026-06-07 | 2026 |         2 |          6 | Junio      |       7 |                 7 | Domingo           | t
   20260608 | 2026-06-08 | 2026 |         2 |          6 | Junio      |       8 |                 1 | Lunes             | f
   20260609 | 2026-06-09 | 2026 |         2 |          6 | Junio      |       9 |                 2 | Martes            | f
   20260610 | 2026-06-10 | 2026 |         2 |          6 | Junio      |      10 |                 3 | Miercoles         | f
   20260611 | 2026-06-11 | 2026 |         2 |          6 | Junio      |      11 |                 4 | Jueves            | f
   20260612 | 2026-06-12 | 2026 |         2 |          6 | Junio      |      12 |                 5 | Viernes           | f
   20260613 | 2026-06-13 | 2026 |         2 |          6 | Junio      |      13 |                 6 | Sabado            | t
   20260614 | 2026-06-14 | 2026 |         2 |          6 | Junio      |      14 |                 7 | Domingo           | t
   20260615 | 2026-06-15 | 2026 |         2 |          6 | Junio      |      15 |                 1 | Lunes             | f
(15 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\dbt_red_metropolitana> docker exec red_metropolitana_postgres psql -U red_admin -d red_metropolitana -c "SELECT MIN(fecha) AS fecha_minima, MAX(fecha) AS fecha_maxima, COUNT(*) AS dias_dimension FROM gold.dim_tiempo;"
 fecha_minima | fecha_maxima | dias_dimension
--------------+--------------+----------------
 2026-06-01   | 2026-07-15   |             45
(1 row)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\dbt_red_metropolitana>
```

Evidencia 12 - Dimensión tiempo con 45 días, desde 2026-06-01 hasta 2026-07-15.

7.3 Dimensiones conformadas

Las dimensiones de modo y zona permitieron centralizar valores compartidos. La dimensión de puntos de servicio integró 104 estaciones de Transmetro, 328 paradas de Transurbano, 22 estaciones de MetroRiel y 14 de Aerómetro, para un total de 468 puntos sin zonas faltantes.

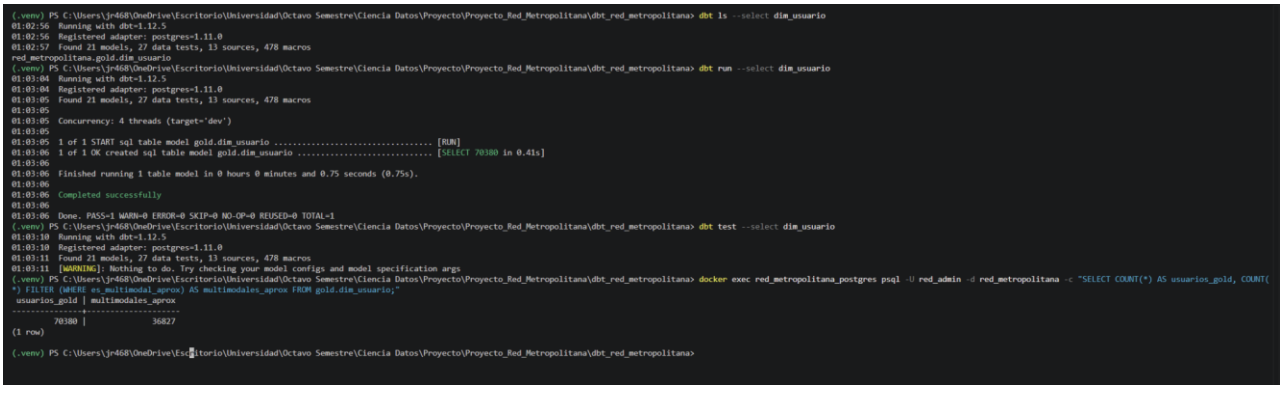
```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana> docker exec red_metropolitana_postgres psql -U red_admin -d red_metropo
litana -c "SELECT * FROM gold.dim_modo_transporte ORDER BY modo_key;"
 modo_key | modo_transporte | tipo_sistema
----------+-----------------+--------------
        1 | Transmetro      | BUS
        2 | Transurbano     | BUS
        3 | MetroRiel       | FERROCARRIL
        4 | Aerometro       | AEREO
(4 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana> docker exec red_metropolitana_postgres psql -U red_admin -d red_metropo
litana -c "SELECT * FROM gold.dim_zona ORDER BY zona_key;"
 zona_key |    zona_nombre    |    tipo_zona
----------+-------------------+------------------
        1 | Mixco             | MUNICIPIO_SECTOR
        2 | San Miguel Petapa | MUNICIPIO_SECTOR
        3 | Villa Nueva       | MUNICIPIO_SECTOR
        4 | Zona 1            | ZONA_URBANA
        5 | Zona 10           | ZONA_URBANA
        6 | Zona 11           | ZONA_URBANA
        7 | Zona 12           | ZONA_URBANA
        8 | Zona 13           | ZONA_URBANA
        9 | Zona 17           | ZONA_URBANA
       10 | Zona 18           | ZONA_URBANA
       11 | Zona 4            | ZONA_URBANA
       12 | Zona 6            | ZONA_URBANA
       13 | Zona 7            | ZONA_URBANA
       14 | Zona 8            | ZONA_URBANA
       15 | Zona 9            | ZONA_URBANA
(15 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana> docker exec red_metropolitana_postgres psql -U red_admin -d red_metropo
litana -c "SELECT COUNT(*) AS zonas_gold FROM gold.dim_zona;"
 zonas_gold
------------
         15
(1 row)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana>
```

Evidencia 13 - Dimensiones de modo de transporte y zona conformada.



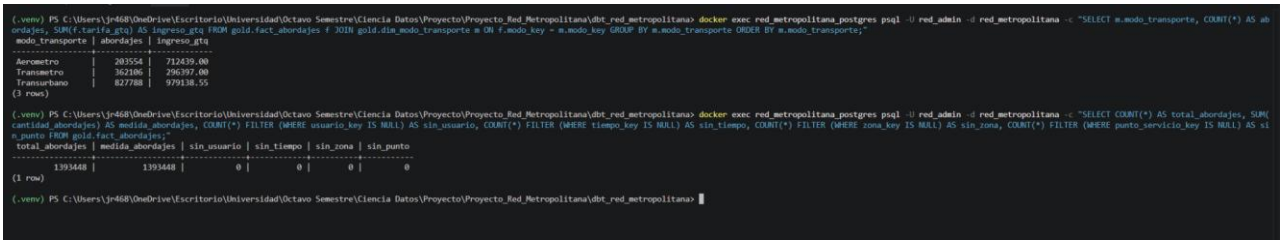
Evidencia 14 - Base de identidad utilizada para la dimensión de usuario.

7.4 Tabla de hechos de abordajes

fact_abordajes unificó los registros válidos de Transmetro, Transurbano y Aerómetro. El total final fue 1,393,448 abordajes. Todas las llaves dimensionales quedaron cubiertas: no hubo filas sin usuario, tiempo, zona o punto de servicio. Las nueve pruebas dbt de la tabla pasaron correctamente.

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana> dbt run --select fact_abordajes
02:05:53  Running with dbt=1.12.5
02:05:53  Registered adapter: postgres=1.11.0
02:05:54  Found 22 models, 40 data tests, 13 sources, 478 macros
02:05:54
02:05:54  Concurrency: 4 threads (target='dev')
02:05:54
02:05:54  1 of 1 START sql table model gold.fact_abordajes ............................... [RUN]
02:05:59  1 of 1 OK created sql table model gold.fact_abordajes .......................... [SELECT 1393448 in
 5.03s]
02:05:59
02:05:59  Finished running 1 table model in 0 hours 0 minutes and 5.31 seconds (5.31s).
02:05:59
02:05:59  Completed successfully
02:05:59
02:05:59  Done. PASS=1 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=1
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana> dbt test --select fact_abordajes
02:10:49  Running with dbt=1.12.5
02:10:49  Registered adapter: postgres=1.11.0
02:10:50  Found 22 models, 40 data tests, 13 sources, 478 macros
02:10:50
02:10:50  Concurrency: 4 threads (target='dev')
02:10:50
02:10:50  1 of 9 START test not_null_fact_abordajes_abordaje_key ......................... [RUN]
02:10:50  2 of 9 START test not_null_fact_abordajes_cantidad_abordajes ................... [RUN]
02:10:50  3 of 9 START test not_null_fact_abordajes_modo_key ............................. [RUN]
02:10:50  4 of 9 START test not_null_fact_abordajes_punto_servicio_key ................... [RUN]
02:10:50  3 of 9 PASS not_null_fact_abordajes_modo_key ................................... [PASS in 0.10s]
02:10:50  1 of 9 PASS not_null_fact_abordajes_abordaje_key ............................... [PASS in 0.10s]
02:10:50  5 of 9 START test not_null_fact_abordajes_tarifa_gtq ........................... [RUN]
02:10:50  6 of 9 START test not_null_fact_abordajes_tiempo_key ........................... [RUN]
02:10:50  2 of 9 PASS not_null_fact_abordajes_cantidad_abordajes ......................... [PASS in 0.12s]
02:10:50  7 of 9 START test not_null_fact_abordajes_usuario_key ........................... [RUN]
02:10:50  4 of 9 PASS not_null_fact_abordajes_punto_servicio_key ......................... [PASS in 0.13s]
02:10:50  8 of 9 START test not_null_fact_abordajes_zona_key ............................. [RUN]
02:10:50  6 of 9 PASS not_null_fact_abordajes_tiempo_key ................................. [PASS in 0.07s]
02:10:50  5 of 9 PASS not_null_fact_abordajes_tarifa_gtq ................................. [PASS in 0.08s]
02:10:50  9 of 9 START test unique_fact_abordajes_abordaje_key ........................... [RUN]
02:10:50  7 of 9 PASS not_null_fact_abordajes_usuario_key ................................ [PASS in 0.08s]
02:10:50  8 of 9 PASS not_null_fact_abordajes_zona_key ................................... [PASS in 0.08s]
02:10:51  9 of 9 PASS unique_fact_abordajes_abordaje_key ................................. [PASS in 0.65s]
02:10:51
02:10:51  Finished running 9 data tests in 0 hours 0 minutes and 1.06 seconds (1.06s).
02:10:51
02:10:51  Completed successfully
02:10:51
02:10:51  Done. PASS=9 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=9
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red
_Metropolitana\dbt_red_metropolitana>
```

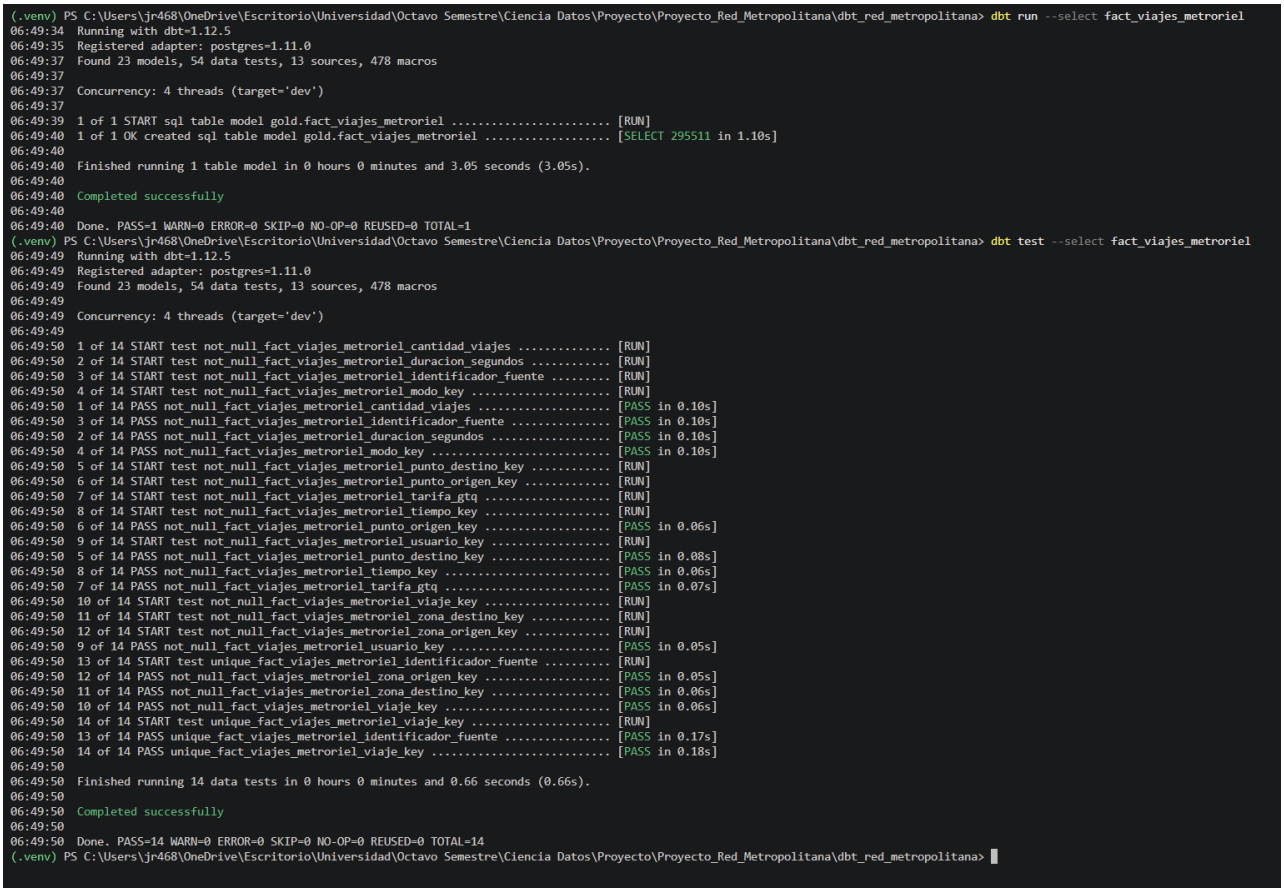
Evidencia 15 - Construcción y 9/9 pruebas aprobadas de fact_abordajes.



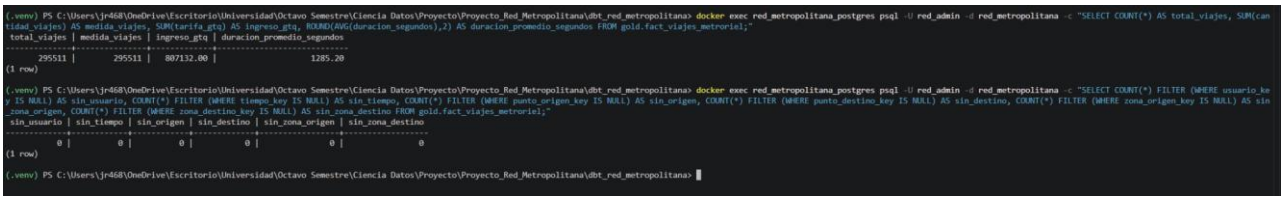
Evidencia 16 - Reconciliación de 1,393,448 abordajes y cobertura dimensional completa.

7.5 Tabla de hechos de viajes MetroRiel

fact_viajes_metroriel conservó el grano de un viaje completo. El resultado fue 295,511 viajes válidos. Se utilizaron roles de origen y destino para punto de servicio y zona. No quedaron llaves dimensionales nulas y las 14 pruebas dbt pasaron correctamente.

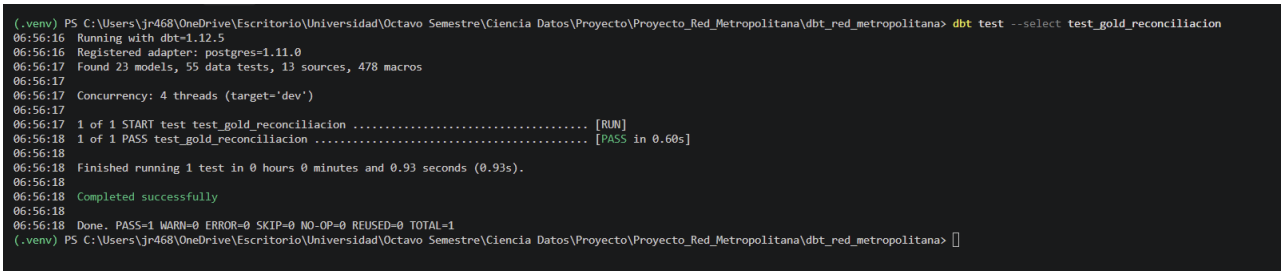


Evidencia 17 - Construcción de fact_viajes_metroriel y 14/14 pruebas dbt aprobadas.

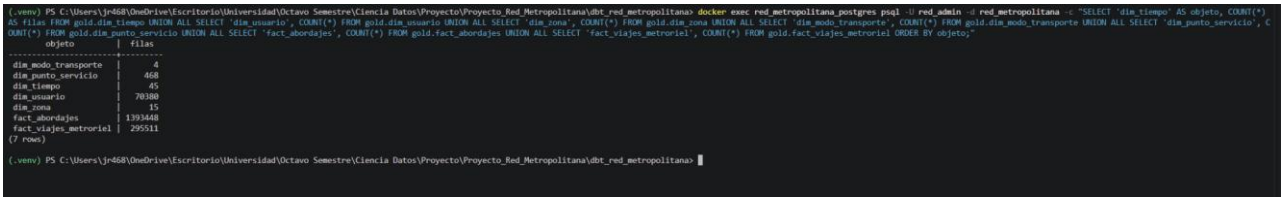


Evidencia 18 - 295,511 viajes, Q807,132.00 de tarifa acumulada y cero llaves dimensionales faltantes.

Finalmente ejecutamos una prueba de reconciliación entre Silver y Gold. La prueba pasó y el resumen de objetos confirmó los conteos esperados de las cinco dimensiones y las dos tablas de hechos.



Evidencia 19 - Prueba de reconciliación Gold aprobada.



Evidencia 20 - Conteos finales del modelo dimensional Gold.

7.6 DDL y materialización de Gold

Los modelos dbt materializan físicamente las cinco dimensiones y las dos tablas de hechos en el esquema gold. Además, para que el entregable incluya un DDL explícito y fácil de revisar, preparamos el archivo sql/ddl_gold.sql con la definición de estas estructuras, sus llaves principales y las relaciones dimensionales.

Objeto	Llave principal
dim_tiempo	tiempo_key
dim_usuario	usuario_key
dim_zona	zona_key
dim_modo_transporte	modo_key
dim_punto_servicio	punto_servicio_key
fact_abordajes	abordaje_key
fact_viajes_metroriel	viaje_key

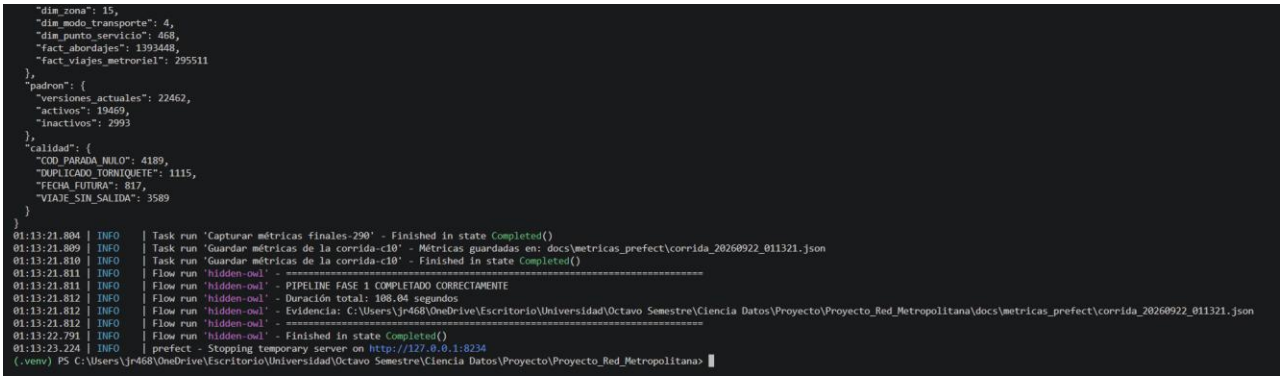
El DDL sirve como documentación de la estructura esperada; la construcción reproducible del modelo continúa realizándose con dbt para mantener las transformaciones y pruebas en un mismo flujo.

8. Orquestación con Prefect

El último bloque técnico fue automatizar la Fase 1. Creamos un flujo de Prefect que valida Bronze, reconstruye Staging, aplica CDC, construye catálogos, ejecuta dbt run, ejecuta dbt test, captura métricas y guarda un JSON con la evidencia de cada corrida. Con esto el pipeline dejó de depender de ejecutar manualmente cada paso.

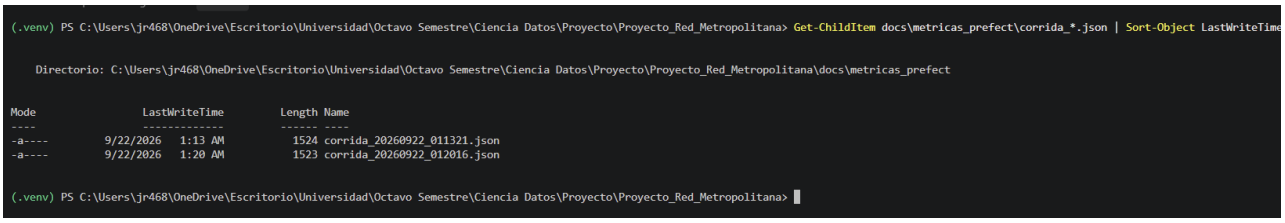
Etapa del flujo	Función
Validar Bronze	Comprobar que todas las fuentes estén completas y reconciliadas
Cargar CDC a Staging	Llevar los eventos Parquet a PostgreSQL
Aplicar CDC	Reconstruir el padrón vigente
Construir catálogos	Preparar usuarios y catálogos de soporte
Cargar operaciones	Reconstruir tablas Staging
dbt run	Construir Silver, cuarentena y Gold
dbt test	Ejecutar validaciones de calidad y reconciliación
Capturar métricas	Guardar conteos y resultados finales

En la primera corrida todos los pasos terminaron correctamente. dbt ejecutó 19 modelos y luego 55 pruebas, todas aprobadas. La duración total fue de 108.04 segundos y se guardó el archivo de métricas de la corrida.



Evidencia 21 - Primera corrida de Prefect: métricas finales y pipeline completado correctamente.

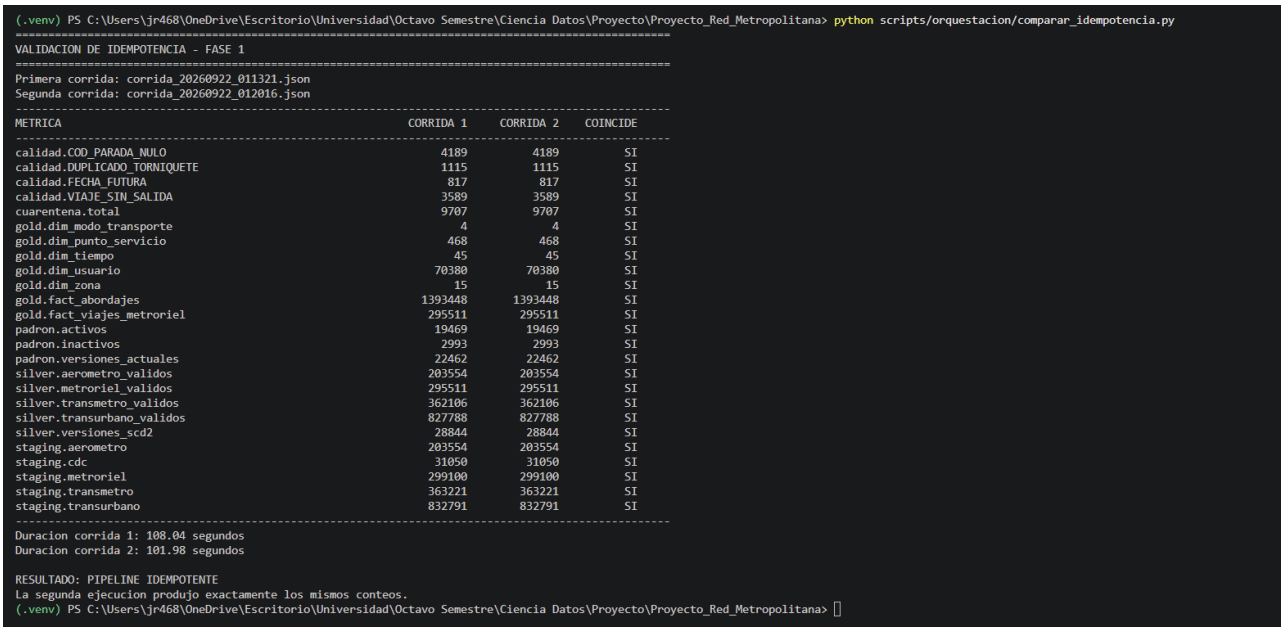
La segunda corrida repitió el proceso completo sin modificar los archivos de entrada. Volvió a generar los mismos conteos y las mismas 55 pruebas pasaron. Esta corrida tardó 101.98 segundos y generó un segundo archivo JSON de métricas.



Evidencia 22 - Archivos JSON de métricas generados por las dos corridas de Prefect.

9. Prueba formal de idempotencia

Para no quedarnos solamente con una comparación visual, hicimos un script que tomó los dos JSON generados por Prefect y comparó cada métrica. La duración podía cambiar, pero los conteos debían ser exactamente iguales. Todas las métricas comparadas coincidieron: calidad, cuarentena, dimensiones, hechos, padrón, Silver y Staging.

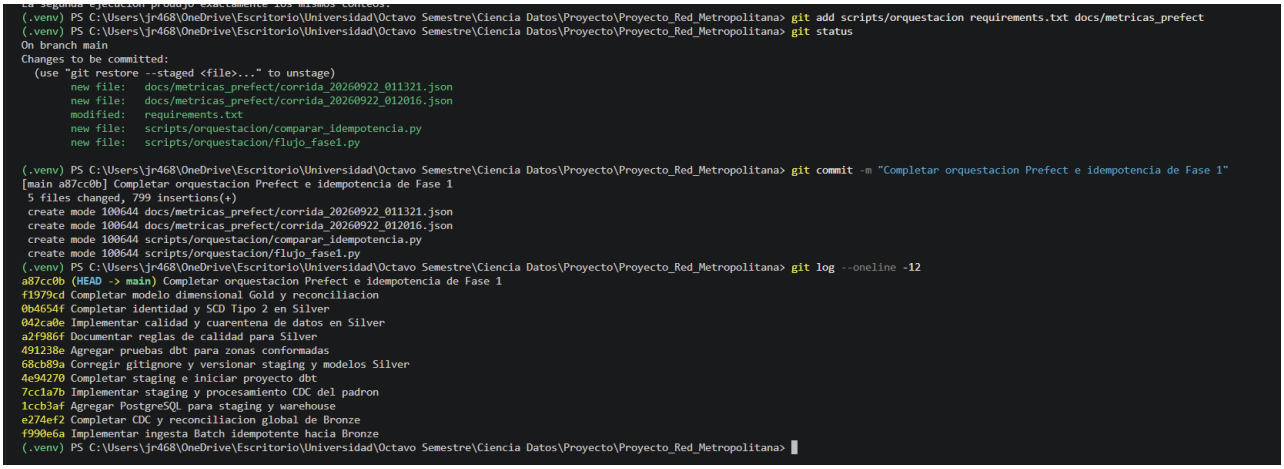


Evidencia 23 - Comparación formal de las dos corridas: todas las métricas coinciden y el resultado es PIPELINE IDEMPOTENTE.

Métrica clave	Corrida 1	Corrida 2
Cuarentena total	9,707	9,707
dim_usuario	70,380	70,380
fact_abordajes	1,393,448	1,393,448
fact_viajes_metroriel	295,511	295,511
Padrón activo	19,469	19,469
Padrón inactivo	2,993	2,993
Silver Transmetro	362,106	362,106
Silver Transurbano	827,788	827,788
Silver MetroRiel	295,511	295,511
Silver Aerómetro	203,554	203,554

10. Control de versiones

El avance también quedó respaldado por commits separados según los bloques principales. El historial muestra el cierre de Bronze, CDC, Staging, calidad, SCD Tipo 2, Gold y Prefect. Esto facilita revisar qué cambió en cada etapa y permite regresar a versiones anteriores si fuera necesario.



Evidencia 24 - Commit final de orquestación e idempotencia y trazabilidad del historial Git.

11. Conclusiones

- Logramos integrar fuentes con estructuras y mecanismos de llegada diferentes sin perder los conteos originales.
- Bronze quedó como una capa reproducible y trazable, lo que permitió reconstruir Staging, Silver y Gold sin volver a depender de los archivos fuente en cada transformación.
- Las reglas de calidad no eliminan datos silenciosamente: los registros problemáticos quedan en cuarentena con una razón clara.
- El padrón mantiene historial mediante SCD Tipo 2, por lo que los cambios de un usuario no reemplazan las versiones anteriores.
- El modelo Gold respeta dos granos de negocio distintos y evita inventar información que las fuentes no contienen.
- La orquestación con Prefect dejó el proceso automatizado y las 55 pruebas dbt sirven como control de calidad global.
- La comparación de las dos corridas demostró que la Fase 1 es idempotente: ejecutar nuevamente el pipeline produce los mismos resultados finales.
- La decisión de procesar Transurbano por batch y mantener Bronze en Parquet dentro del lake dejó una separación clara entre la capa cruda y el warehouse relacional.
- El modelo dimensional quedó respaldado por matriz del bus, definición de grano, clasificación de medidas y un DDL explícito para las dimensiones y tablas de hechos de Gold.

12. Resumen final de evidencias

Bloque	Evidencia principal	Resultado
Fuentes	Inventario inicial	1,730,184 registros
Streaming	Kafka Transmetro/Aerómetro	Publicación y consumo verificados
Bronze	Inventario global	1,730,184 / 1,730,184
CDC	Carga y aplicación	31,050 eventos; 22,462 tarjetas actuales
Silver	Calidad y cuarentena	9,707 registros únicos en cuarentena
Identidad	Integración aproximada	36,827 identidades multimodales aproximadas
SCD2	Historial de padrón	28,844 versiones; 1 actual por tarjeta
Gold	Modelo dimensional	5 dimensiones + 2 hechos
dbt	Pruebas globales	55/55 PASS
Prefect	Corrida 1	108.04 s
Prefect	Corrida 2	101.98 s
Idempotencia	Comparación de JSON	Todas las métricas coinciden

13. Correspondencia con los entregables de la Fase 1

Para facilitar la revisión en el repositorio, organizamos la relación entre lo solicitado y los archivos que lo implementan o documentan.

Inciso	Implementación / evidencia principal
1.1 Ingesta por vía	scripts/streaming/productor_transmetro.py; scripts/streaming/productor_aerometro.py; scripts/batch/cargar_batch_bronze.py; scripts/cdc/cargar_cdc_bronze.py. Transurbano se justifica por batch y Bronze se conserva en Parquet.
1.2 CDC y llaves únicas	scripts/staging/cargar_cdc_staging.py; scripts/staging/aplicar_cdc_padron.py; scripts/staging/construir_catalogos_usuarios.py. Incluye secuencia INSERT/UPDATE/DELETE y conteos por operador.
1.3 Silver	dbt_red_metropolitana/models/silver/ y models/cuarentena/. Incluye formatos, zonas conformadas, identidad aproximada, reglas de calidad, cuarentena y SCD Tipo 2.
1.4 Gold	dbt_red_metropolitana/models/gold/; docs/matriz_bus.md; docs/modelo_dimensional.md; sql/ddl_gold.sql. Incluye dos hechos, cinco dimensiones, granos y medidas.
1.5 Orquestación	scripts/orquestacion/flujo_fase1.py; scripts/orquestacion/comparar_idempotencia.py; docs/metricas_prefect/. Evidencia dos corridas con conteos idénticos.

Con esta organización, cada inciso publicado para la entrega puede ubicarse directamente en el repositorio y también queda respaldado por las evidencias incluidas en este documento.