Universidad Rafael Landivar
Facultad de ingeniería

Ciencia de Datos

Ing. Max Cerna



Fase 2 Proyecto

José Rodrigo Rosales Mirón – 1143323

Paula Ximena Navarro Ruano – 1006323

Eddy Paolo Marroquín Montenegro – 1146822

Guatemala 12 de octubre de 2026

Este documento reúne las evidencias más relevantes obtenidas durante la Fase 2 del proyecto. Se documentan los cambios realizados en Gold, la preparación de métricas para el tablero, la seudonimización de usuarios, los marts analíticos, los dashboards en Tableau, la capa de features, el linaje de datos y la validación final del proyecto. Se seleccionaron únicamente capturas que aportan evidencia técnica o analítica y se evitó repetir pantallas intermedias que no agregaban información.

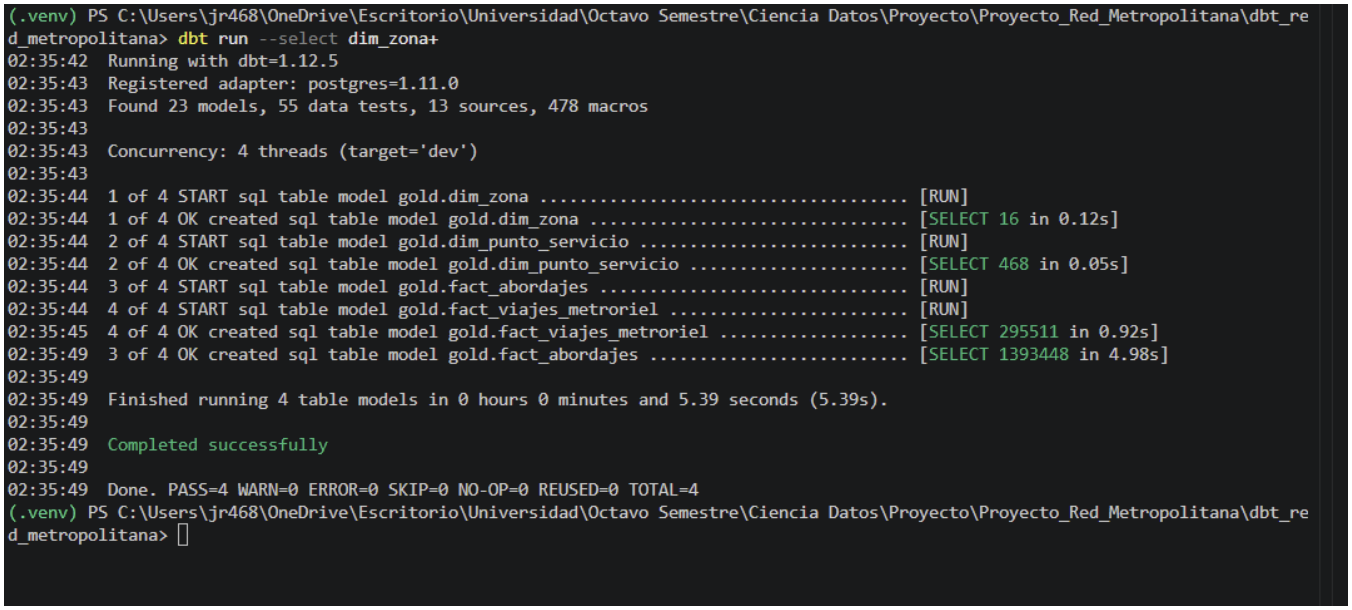
1. Resumen de resultados de la Fase 2

Componente	Resultado
Cobertura	15 de 16 zonas analizadas tienen al menos un modo de servicio. Santa Catarina Pinula queda sin cobertura.
Dimensión de tiempo	Se amplió a grano horario: 1,080 filas para 45 fechas × 24 horas, con identificación de hora pico y día hábil.
Seudonimización	Se generaron 70,380 seudónimos distintos a partir de 70,380 identidades aproximadas, sin nulos.
Marts Tableau	Se construyeron marts de demanda horaria, cobertura, multimodalidad y evaluación de MetroRiel.
Multimodalidad	36,827 de 70,380 usuarios son multimodales aproximados (52.33%).
Tableau	Se finalizaron dos dashboards: Panorama General y Multimodalidad/Evaluación MetroRiel.
Features	Se construyó una tabla con una fila por usuario, 70,380 filas y fecha de corte 2026-07-15.
Validación final	La ejecución integral terminó con 25 modelos ejecutados correctamente y 89 pruebas aprobadas, sin errores.

2. Preparación de Gold para análisis de cobertura y demanda

El primer bloque de Fase 2 preparó la capa Gold para responder las preguntas del tablero. Se reforzó la dimensión de zona con el indicador de servicio y se amplió la dimensión de tiempo hasta un grano horario, permitiendo diferenciar horas pico y horas fuera de pico.

Evidencia 1 — Reconstrucción de Gold para cobertura



Se muestra la ejecución de dbt sobre dim_zona y sus modelos dependientes. El proceso terminó correctamente con 4 modelos creados, incluyendo 16 zonas, 468 puntos de servicio, 1,393,448 abordajes y 295,511 viajes de MetroRiel. Esto confirma que los cambios de cobertura se propagaron sin romper el modelo dimensional.

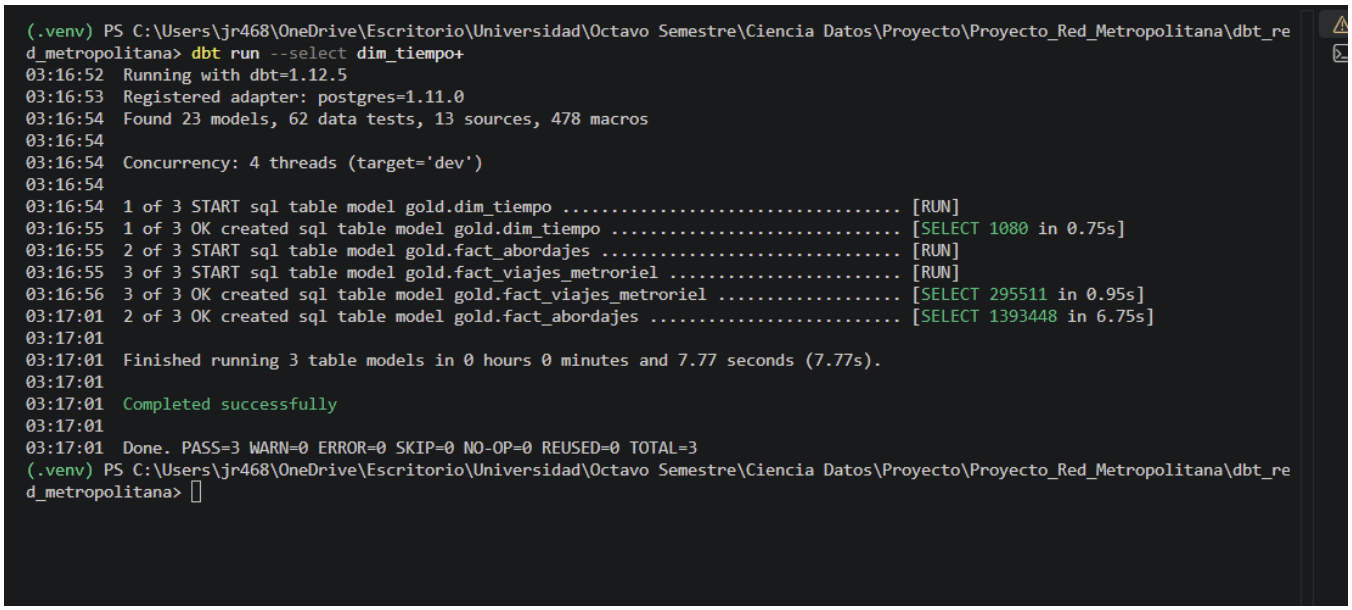
Evidencia 2 — Validación de zonas con y sin servicio

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docke
r compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT zona_key, zona_nombre, tipo_zona, tiene_servicio FROM go
ld.dim_zona ORDER BY zona_key;"
 zona_key |      zona_nombre      |    tipo_zona     | tiene_servicio
----------+-----------------------+------------------+----------------
        1 | Mixco                 | MUNICIPIO_SECTOR | t
        2 | San Miguel Petapa     | MUNICIPIO_SECTOR | t
        3 | Santa Catarina Pinula | MUNICIPIO_SECTOR | f
        4 | Villa Nueva           | MUNICIPIO_SECTOR | t
        5 | Zona 1                | ZONA_URBANA      | t
        6 | Zona 10               | ZONA_URBANA      | t
        7 | Zona 11               | ZONA_URBANA      | t
        8 | Zona 12               | ZONA_URBANA      | t
        9 | Zona 13               | ZONA_URBANA      | t
       10 | Zona 17               | ZONA_URBANA      | t
       11 | Zona 18               | ZONA_URBANA      | t
       12 | Zona 4                | ZONA_URBANA      | t
       13 | Zona 6                | ZONA_URBANA      | t
       14 | Zona 7                | ZONA_URBANA      | t
       15 | Zona 8                | ZONA_URBANA      | t
       16 | Zona 9                | ZONA_URBANA      | t
(16 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana>
```

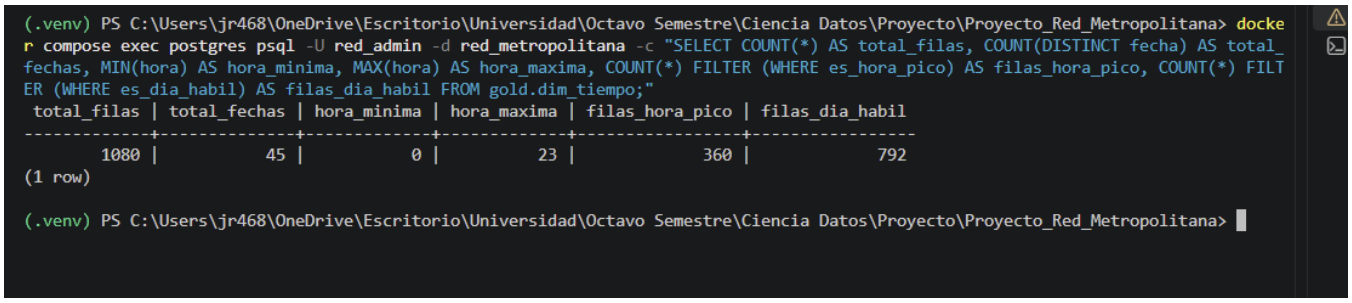
La consulta a gold.dim_zona confirma las 16 zonas analizadas y el indicador tiene_servicio. Santa Catarina Pinula aparece con valor falso, mientras las otras 15 zonas tienen al menos un modo disponible. Este resultado se convirtió después en uno de los hallazgos principales del tablero.

Evidencia 3 — Dimensión de tiempo a grano horario



Se ejecutó dim_tiempo junto con los hechos que dependen de ella. La dimensión quedó con 1,080 filas y los hechos se reconstruyeron correctamente. El cambio permitió analizar demanda por hora sin perder la relación con los modelos Gold existentes.

Evidencia 4 — Comprobación de calendario y horas pico

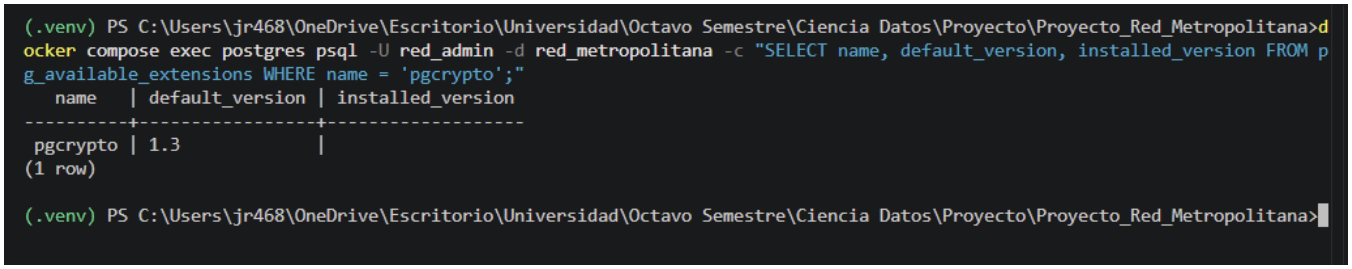


La validación resume 1,080 filas, 45 fechas y 24 horas posibles (0 a 23). También confirma 360 filas clasificadas como hora pico y 792 como día hábil. Con esto se verificó que la lógica temporal quedara lista para los análisis de Tableau.

3. Seguridad, identidad y seudonimización

La Fase 2 exigía que Gold no expusiera llaves originales de usuarios. Para cumplirlo se habilitó pgcrypto, se construyó un modelo Silver de seudonimización y se actualizó la dimensión de usuario y los hechos para trabajar con el identificador seudonimizado.

Evidencia 5 — Disponibilidad de pgcrypto



La consulta a PostgreSQL confirma que la extensión pgcrypto versión 1.3 está disponible. Esta extensión permite generar HMAC-SHA256 para seudonimizar las identidades antes de llegar a Gold.

Evidencia 6 — Construcción del modelo de identidades seudonimizadas

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\d
bt_red_metropolitana> dbt run --select silver_identidad_usuarios_seudonimizada
04:16:52  Running with dbt=1.12.5
04:16:52  Registered adapter: postgres=1.11.0
04:16:53  Found 24 models, 62 data tests, 13 sources, 478 macros
04:16:53
04:16:53  Concurrency: 4 threads (target='dev')
04:16:53
04:16:53  1 of 1 START sql table model silver.silver_identidad_usuarios_seudonimizada .... [RUN]
04:16:54  1 of 1 OK created sql table model silver.silver_identidad_usuarios_seudonimizada  [SELECT 117203 in 0.48s]
04:16:54
04:16:54  Finished running 1 table model in 0 hours 0 minutes and 0.79 seconds (0.79s).
04:16:54
04:16:54  Completed successfully
04:16:54
04:16:54  Done. PASS=1 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=1
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\d
bt_red_metropolitana>
```

dbt materializó silver_identidad_usuarios_seudonimizada con 117,203 filas y sin errores. El modelo se ubica en Silver, por lo que la protección de la identidad ocurre antes de la capa analítica Gold.

Evidencia 7 — Validación de unicidad y ausencia de nulos en seudónimos

```
Problems  Output  Debug Console  Terminal  Ports                                                    powershell

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana>d
ocker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT COUNT(*) AS filas_fuente, COUNT(DISTINCT usuari
o_integrado_aprox) AS identidades_aprox, COUNT(DISTINCT usuario_seudonimo) AS seudonimos_distintos, COUNT(*) FILTER (WHERE us
uario_seudonimo IS NULL OR usuario_seudonimo = '') AS seudonimos_nulos FROM silver.silver_identidad_usuarios_seudonimizada;"
 filas_fuente | identidades_aprox | seudonimos_distintos | seudonimos_nulos
--------------+-------------------+----------------------+------------------
       117203 |             70380 |                70380 |                0
(1 row)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana>
```

Se comparó el total de filas, las identidades aproximadas y los seudónimos distintos. Se obtuvieron 117,203 filas fuente, 70,380 identidades aproximadas, 70,380 seudónimos distintos y 0 seudónimos nulos. Esto confirma consistencia uno a uno a nivel de identidad integrada.

Evidencia 8 — Pruebas posteriores a la seudonimización

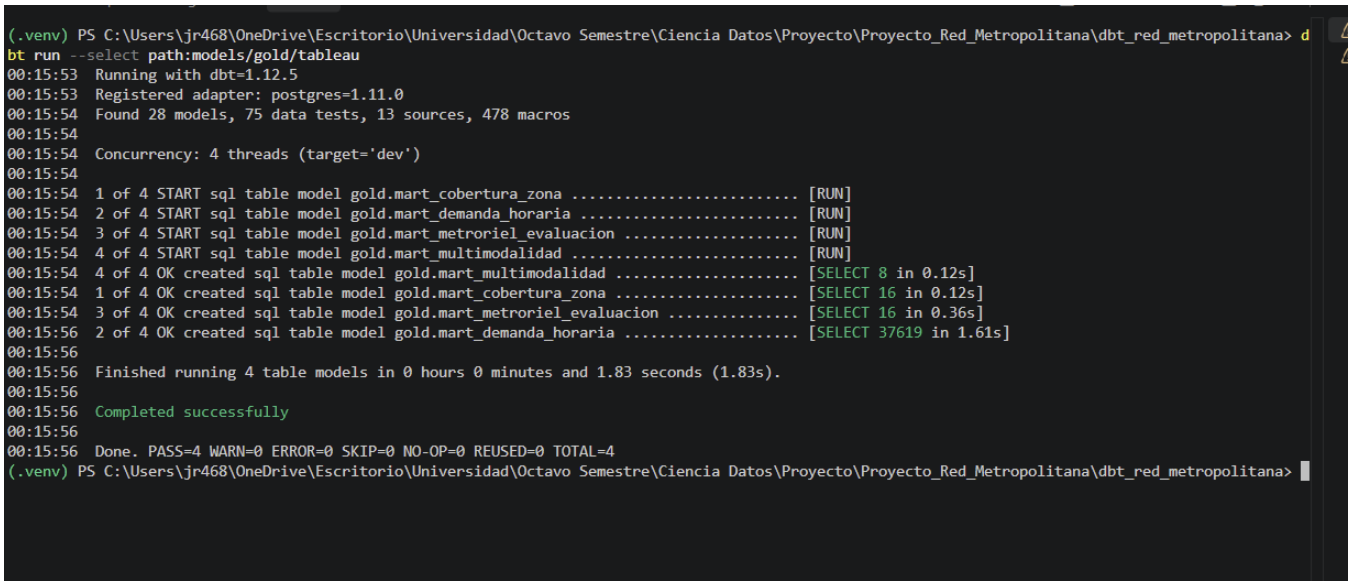
```
00:03:51  69 of 75 PASS unique_dim_usuario_usuario_seudonimo ..... [PASS in 0.07s]
00:03:51  71 of 75 PASS unique_dim_zona_zona_nombre ..... [PASS in 0.03s]
00:03:51  72 of 75 START test unique_fact_abordajes_abordaje_key ..... [RUN]
00:03:51  73 of 75 START test unique_fact_viajes_metroriel_identificador_fuente ..... [RUN]
00:03:51  70 of 75 PASS unique_dim_zona_zona_key ..... [PASS in 0.06s]
00:03:51  62 of 75 PASS test_seudonimo_sin_colisiones ..... [PASS in 0.26s]
00:03:51  74 of 75 START test unique_fact_viajes_metroriel_viaje_key ..... [RUN]
00:03:51  75 of 75 START test unique_silver_padron_usuarios_scd2_version_id ..... [RUN]
00:03:51  75 of 75 PASS unique_silver_padron_usuarios_scd2_version_id ..... [PASS in 0.06s]
00:03:51  74 of 75 PASS unique_fact_viajes_metroriel_viaje_key ..... [PASS in 0.17s]
00:03:51  73 of 75 PASS unique_fact_viajes_metroriel_identificador_fuente ..... [PASS in 0.20s]
00:03:51  72 of 75 PASS unique_fact_abordajes_abordaje_key ..... [PASS in 0.71s]
00:03:51
00:03:51  Finished running 75 data tests in 0 hours 0 minutes and 2.14 seconds (2.14s).
00:03:52
00:03:52  Completed successfully
00:03:52
00:03:52  Done. PASS=75 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=75
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana\dbt_red_metropolitana>
```

Luego de integrar la seudonimización en Gold se ejecutó la suite de pruebas disponible hasta ese punto. Las 75 pruebas finalizaron en estado PASS, incluyendo consistencia y ausencia de colisiones de seudónimos.

4. Marts analíticos y construcción del tablero en Tableau

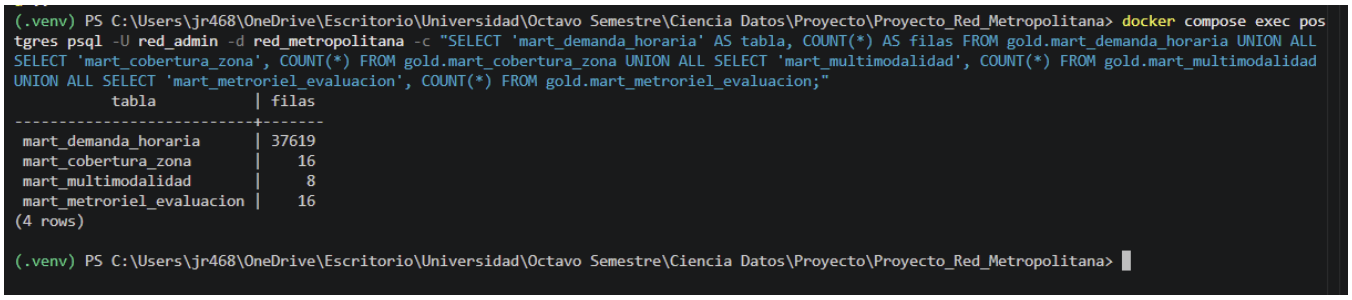
Para evitar consultas complejas directamente sobre los hechos, se construyeron cuatro marts en Gold. Estos modelos consolidan la información que Tableau necesita para demanda horaria, cobertura, multimodalidad y evaluación del trazado de MetroRiel.

Evidencia 9 — Construcción de los marts para Tableau



La ejecución generó correctamente cuatro modelos: mart_cobertura_zona, mart_demanda_horaria, mart_metroriel_evaluacion y mart_multimodalidad. Todos terminaron sin errores y quedaron disponibles en el esquema Gold.

Evidencia 10 — Conteos de los marts analíticos



Se verificaron los tamaños de los marts: demanda horaria 37,619 filas, cobertura 16, multimodalidad 8 y evaluación de MetroRiel 16. Estos conteos coinciden con el grano esperado para cada análisis.

Evidencia 11 — Conexión de Tableau a PostgreSQL/Gold

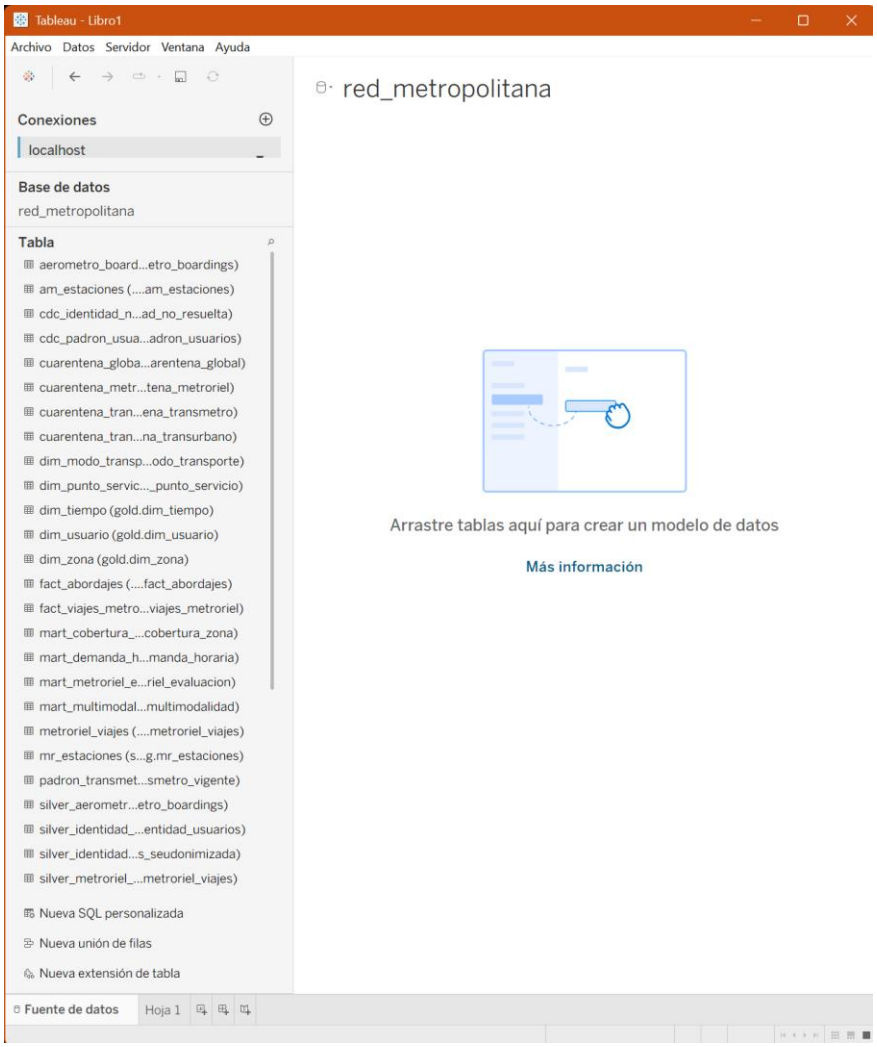
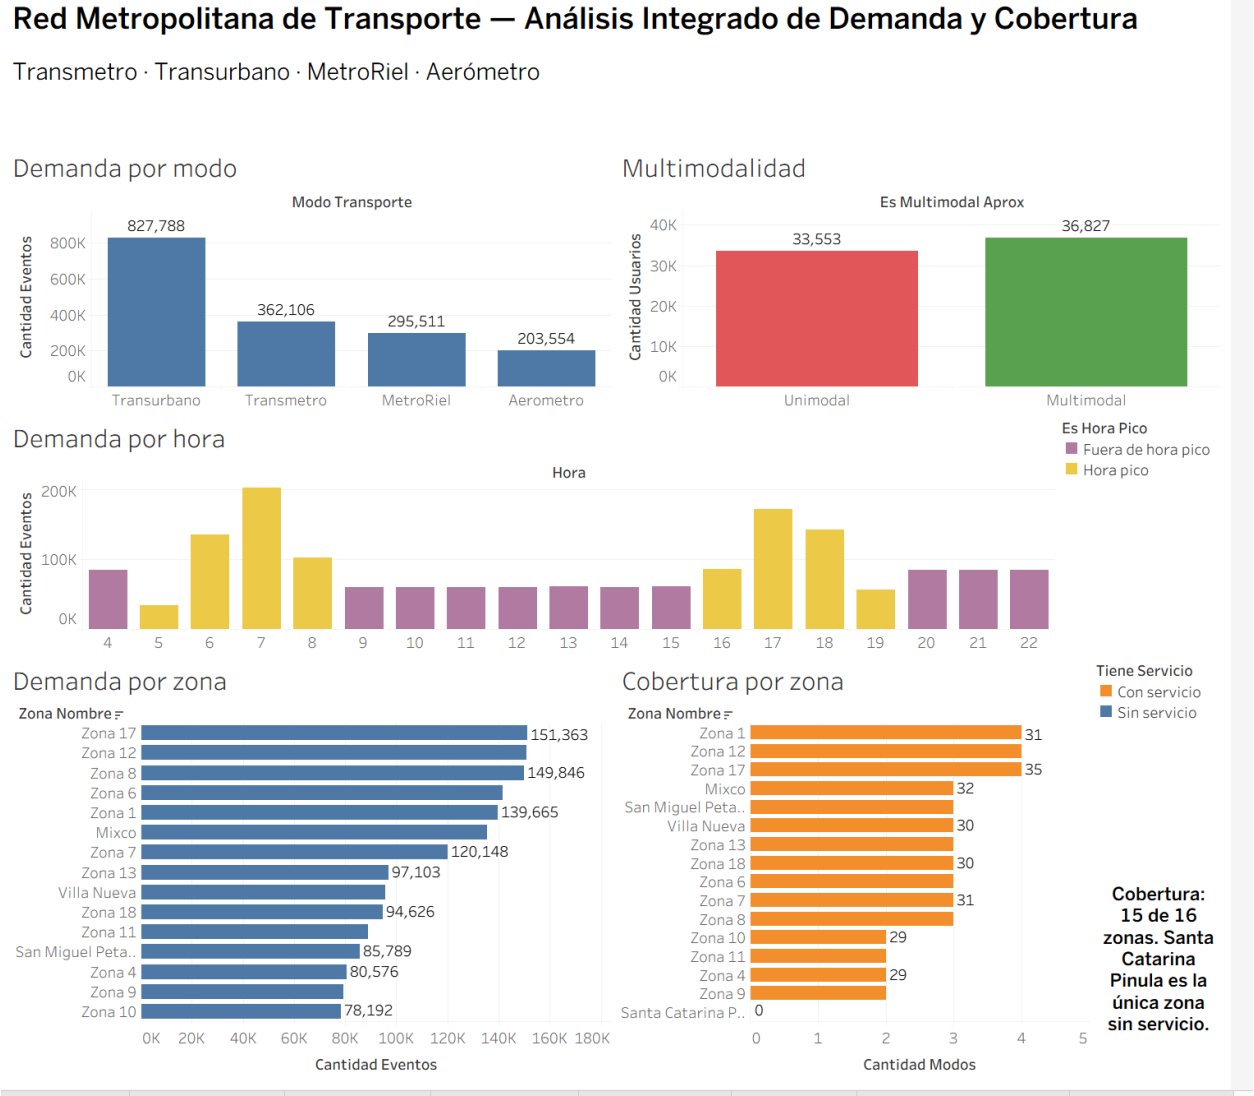


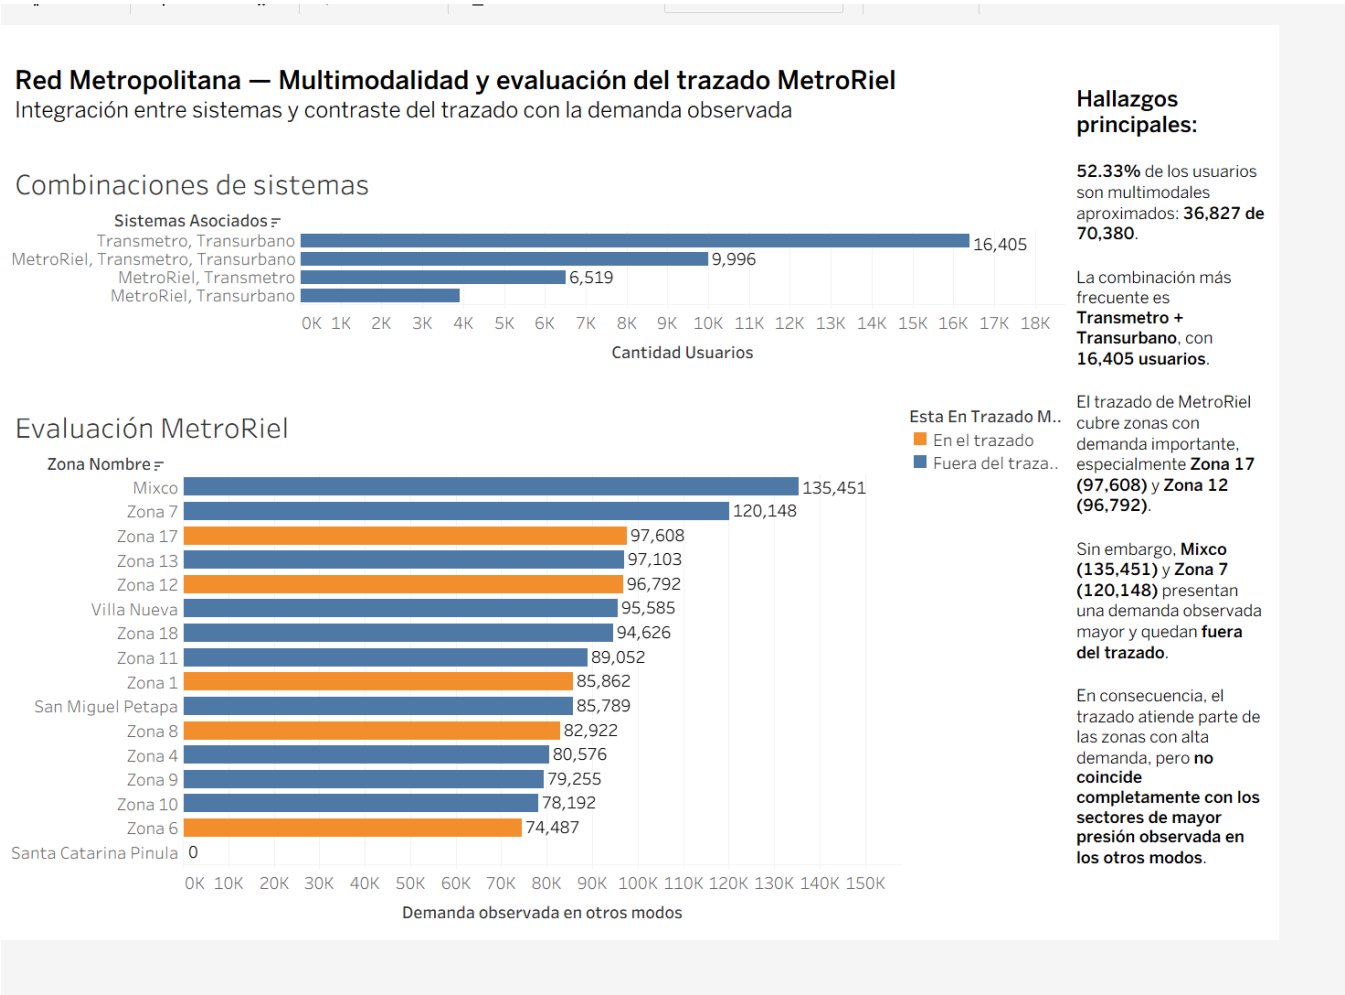
Tableau quedó conectado a la base red_metropolitana en PostgreSQL. En el panel de tablas se observan dimensiones, hechos y marts de Gold, demostrando que el tablero consume directamente la capa analítica preparada en dbt.

Evidencia 12 — Dashboard 1 — Panorama General: demanda y cobertura



El dashboard principal integra demanda por modo, hora y zona, multimodalidad y cobertura. Entre los resultados visibles están 827,788 eventos de Transurbano, 36,827 usuarios multimodales y la brecha de cobertura en Santa Catarina Pinula.

Evidencia 13 — Dashboard 2 — Multimodalidad y evaluación de MetroRiel

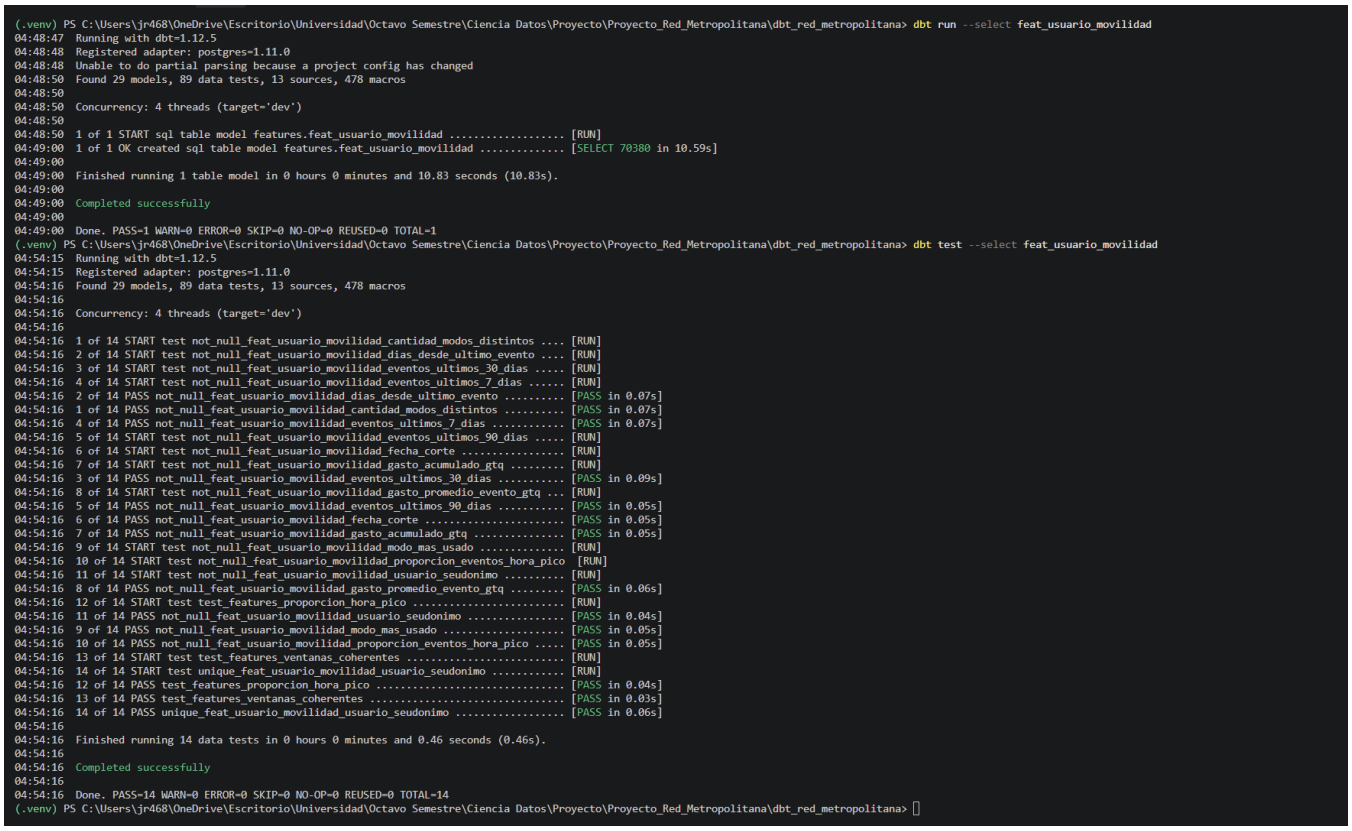


El segundo dashboard compara combinaciones de sistemas y contrasta el trazado de MetroRiel con la demanda observada en otros modos. Se identificó que Mixco (135,451) y Zona 7 (120,148) presentan alta demanda y quedan fuera del trazado, mientras Zona 17 y Zona 12 sí forman parte del recorrido propuesto.

5. Capa de features para Ciencia de Datos

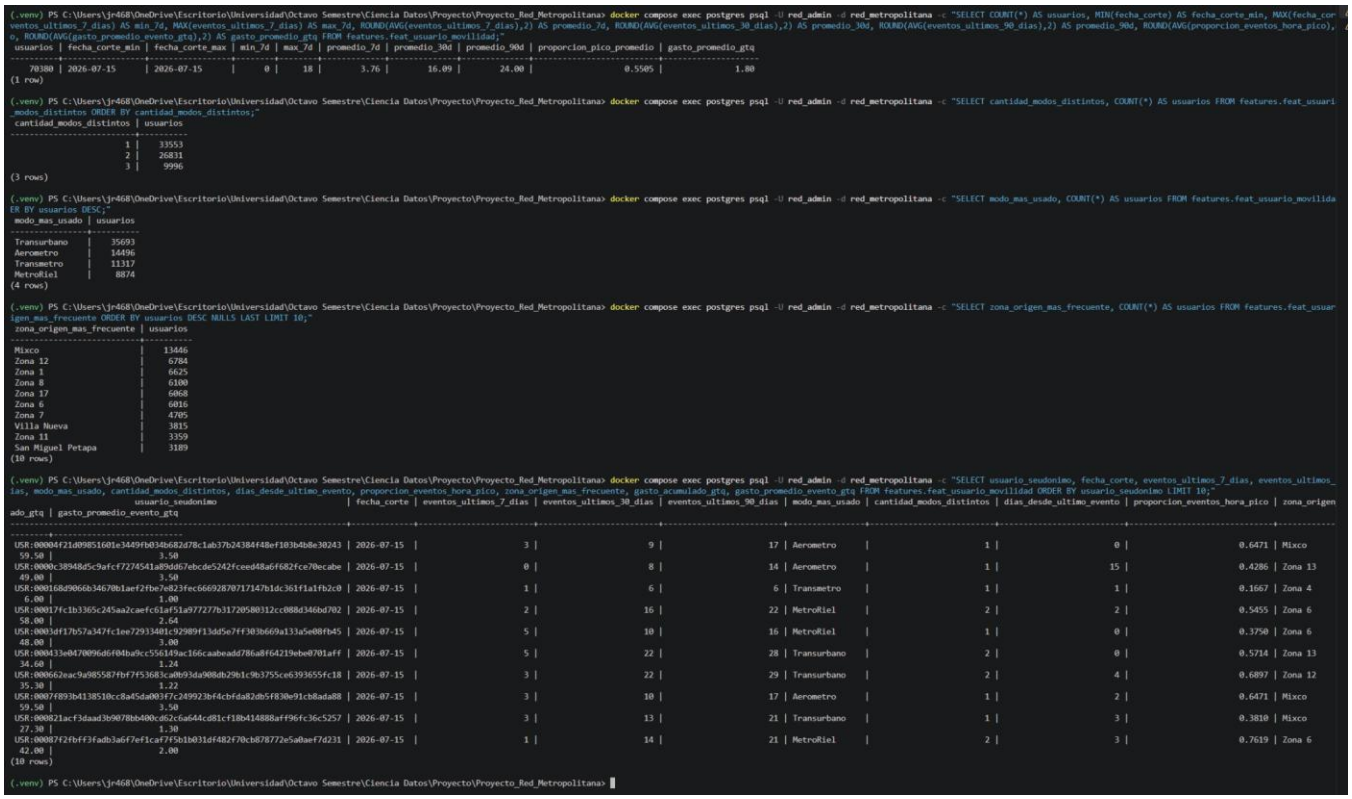
Además del tablero, se construyó una tabla de features desde Silver, no desde Gold. El grano es una fila por usuario seudonimizado y las variables resumen actividad reciente, modo principal, diversidad modal, recencia, hora pico, zona frecuente y gasto.

Evidencia 14 — Construcción y pruebas de la tabla de features



El modelo features.feat_usuario_movilidad se materializó en el esquema features con 70,380 filas. Las 14 pruebas específicas del modelo pasaron correctamente, incluyendo unicidad, no nulidad, coherencia de ventanas 7/30/90 días y rango válido de la proporción en hora pico.

Evidencia 15 — Perfil de la tabla de features



```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT COUNT(*) AS usuarios, MIN(fecha_corte) AS fecha_corte_min, MAX(fecha_cor
ventos_ultimos_7_dias) AS min_7d, MAX(eventos_ultimos_7_dias) AS max_7d, ROUND(AVG(eventos_ultimos_7_dias),2) AS promedio_7d, ROUND(AVG(eventos_ultimos_30_dias),2) AS promedio_30d, ROUND(AVG(eventos_ultimos_90_dias),2) AS promedio_90d, ROUND(AVG(proporcion_eventos_hora_pico),
o, ROUND(AVG(gasto_promedio_evento_gtq),2) AS gasto_promedio_gtq FROM features.feat_usuario_movilidad;"
 usuarios | fecha_corte_min | fecha_corte_max | min_7d | max_7d | promedio_7d | promedio_30d | promedio_90d | proporcion_pico_promedio | gasto_promedio_gtq
----------+-----------------+-----------------+--------+--------+-------------+--------------+--------------+--------------------------+--------------------
    70380 | 2026-07-15      | 2026-07-15      |      0 |     18 |        3.76 |        16.09 |        24.00 |                   0.5505 |               1.80
(1 row)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT cantidad_modos_distintos, COUNT(*) AS usuarios FROM features.feat_usuari
_modos_distintos ORDER BY cantidad_modos_distintos;"
 cantidad_modos_distintos | usuarios
--------------------------+----------
                        1 |    33553
                        2 |    26831
                        3 |     9996
(3 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT modo_mas_usado, COUNT(*) AS usuarios FROM features.feat_usuario_movilida
ER BY usuarios DESC;"
 modo_mas_usado | usuarios
----------------+----------
 Transurbano    |    35693
 Aerometro      |    14496
 Transmetro     |    11317
 MetroRiel      |     8874
(4 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT zona_origen_mas_frecuente, COUNT(*) AS usuarios FROM features.feat_usuar
igen_mas_frecuente ORDER BY usuarios DESC NULLS LAST LIMIT 10;"
 zona_origen_mas_frecuente | usuarios
---------------------------+----------
 Mixco                     |    13446
 Zona 12                   |     6784
 Zona 1                    |     6625
 Zona 8                    |     6100
 Zona 17                   |     6068
 Zona 6                    |     6016
 Zona 7                    |     4705
 Villa Nueva               |     3815
 Zona 11                   |     3359
 San Miguel Petapa         |     3189
(10 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana> docker compose exec postgres psql -U red_admin -d red_metropolitana -c "SELECT usuario_seudonimo, fecha_corte, eventos_ultimos_7_dias, eventos_ultimos_
ias, modo_mas_usado, cantidad_modos_distintos, dias_desde_ultimo_evento, proporcion_eventos_hora_pico, zona_origen_mas_frecuente, gasto_acumulado_gtq, gasto_promedio_evento_gtq FROM features.feat_usuario_movilidad ORDER BY usuario_seudonimo LIMIT 10;"
                  usuario_seudonimo                  | fecha_corte | eventos_ultimos_7_dias | eventos_ultimos_30_dias | eventos_ultimos_90_dias | modo_mas_usado | cantidad_modos_distintos | dias_desde_ultimo_evento | proporcion_eventos_hora_pico | zona_origen
ado_gtq | gasto_promedio_evento_gtq
----------------------------------------------------------------------+-------------+------------------------+-------------------------+-------------------------+----------------+--------------------------+--------------------------+------------------------------+-----------
--------+---------------------------
 USR:00004f21d09851601e3449fb034b682d78c1ab37b24384f48ef103b4b8e30243 | 2026-07-15  |                      3 |                       9 |                      17 | Aerometro      |                        1 |                        0 |                       0.6471 | Mixco
  59.50 |                      3.50
 USR:0008c38948d5c9afcf7274541a89dd67ebcde5242fceed48a6f682fce70ecabe | 2026-07-15  |                      0 |                       8 |                      14 | Aerometro      |                        1 |                       15 |                       0.4286 | Zona 13
  49.00 |                      3.50
 USR:000168d9066b34670b1aef2fbe7e823fec66692870717147b1dc361f1a1fb2c0 | 2026-07-15  |                      1 |                       6 |                       6 | Transmetro     |                        1 |                        1 |                       0.1667 | Zona 4
   6.00 |                      1.00
 USR:00017fc1b3365c245aa2caefc61af51a977277b1720580312cc088d346bd702 | 2026-07-15  |                      2 |                      16 |                      22 | MetroRiel      |                        2 |                        2 |                       0.5455 | Zona 6
  58.00 |                      2.64
 USR:0003df17b57a347fc1ee72933401c92989f13dd5e7ff303b669a133a5e08fb45 | 2026-07-15  |                      5 |                      10 |                      16 | MetroRiel      |                        1 |                        0 |                       0.3750 | Zona 6
  48.00 |                      3.00
 USR:000433e0470096d6f04ba9cc556149ac166caabeadd786a8f64219ebe0701aff | 2026-07-15  |                      5 |                      22 |                      28 | Transurbano    |                        2 |                        0 |                       0.5714 | Zona 13
  34.60 |                      1.24
 USR:000662eac9a985587fbf7f53683ca0b93da908db29b1c9b3755ce6393655fc18 | 2026-07-15  |                      3 |                      22 |                      29 | Transurbano    |                        2 |                        4 |                       0.6897 | Zona 12
  35.30 |                      1.22
 USR:0007f893b4138510cc8a45da00347c249923bf4cbfda82db5f830e91cb8ada88 | 2026-07-15  |                      3 |                      10 |                      17 | Aerometro      |                        1 |                        2 |                       0.6471 | Mixco
  59.50 |                      3.50
 USR:000821acf3daad3b9078bb400cd62c6a644cd81cf18b414888aff96fc36c5257 | 2026-07-15  |                      3 |                      13 |                      21 | Transurbano    |                        1 |                        3 |                       0.3810 | Mixco
  27.30 |                      1.30
 USR:00087f2fbff3fadb3a6f7ef1caf7f5b1b031df482f70cb878772e5a0aef7d231 | 2026-07-15  |                      1 |                      14 |                      21 | MetroRiel      |                        2 |                        3 |                       0.7619 | Zona 6
  42.00 |                      2.00
(10 rows)

(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto_Red_Metropolitana>
```

Las consultas de validación muestran fecha de corte 2026-07-15, promedios de 3.76 eventos en 7 días, 16.09 en 30 días y 24.00 en la ventana disponible de hasta 90 días. También se observa la distribución por cantidad de modos, el modo más usado y las zonas de origen más frecuentes, además de ejemplos de filas con identificadores seudonimizados.

6. Gobernanza y trazabilidad

Como parte del cierre de Fase 2 se documentaron definiciones oficiales, responsables por dominio, diccionario de Gold, reglas de calidad y estrategia de identidad. También se generó el linaje de dbt para poder rastrear una métrica desde los modelos analíticos hasta las fuentes y transformaciones previas.

Evidencia 16 — Linaje de fact_abordajes generado por dbt



El grafo muestra el recorrido desde tablas de Staging y modelos intermedios/Silver hasta dimensiones Gold, fact_abordajes y marts analíticos. También se observa la ruta de seudonimización hacia dim_usuario. Esta evidencia respalda la trazabilidad requerida para el tablero y la gobernanza del warehouse.

7. Validación integral y cierre del repositorio

Al finalizar la Fase 2 se ejecutó nuevamente el proyecto completo para comprobar que los cambios nuevos no afectaran los componentes existentes. La ejecución final detectó 29 modelos en el proyecto; 25 modelos materializados se ejecutaron correctamente y la suite completa de 89 pruebas terminó sin errores.

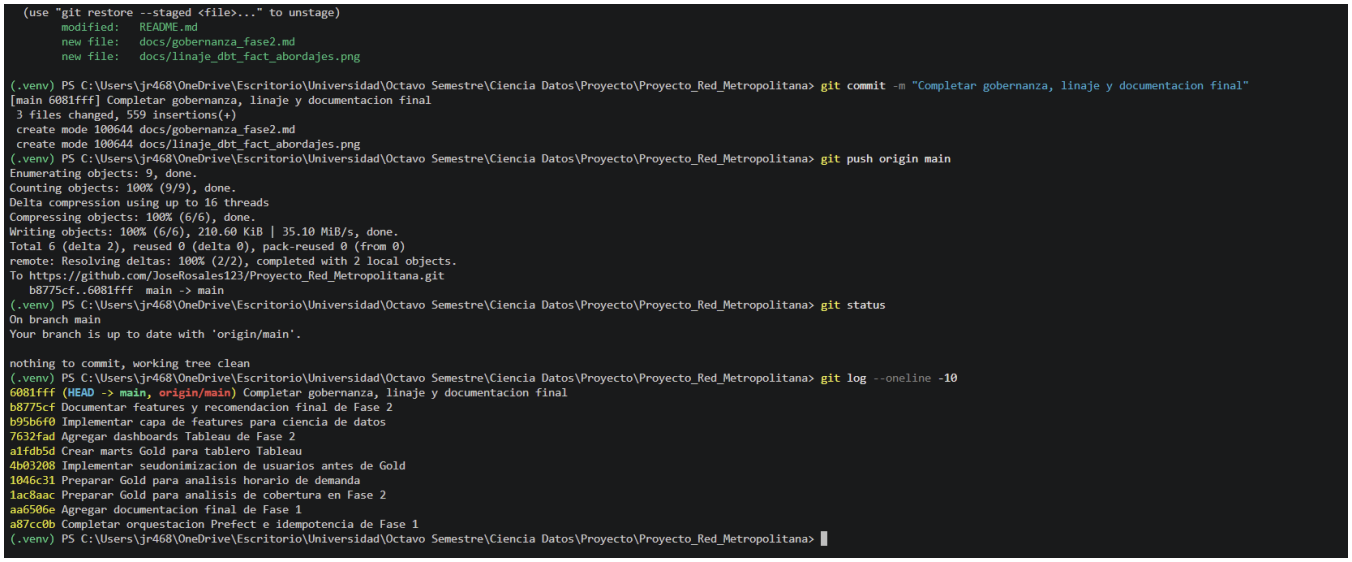
Validación final de dbt

```
dbt                                                                                run
Found       29       models,       89       data       tests,       13       sources,       478       macros
Finished          running          25          table          models          in          19.06          seconds
Completed                                                                                 successfully
PASS=25                  WARN=0                  ERROR=0                  SKIP=0                  TOTAL=25

dbt                                                                                  test
Found       29       models,       89       data       tests,       13       sources,       478       macros
Finished          running          89            data            tests          in          2.28          seconds
Completed                                                                                 successfully
PASS=89  WARN=0  ERROR=0  SKIP=0  TOTAL=89
```

Esta validación final confirma que la integración completa de Fase 2 quedó estable: cobertura, tiempo horario, seudonimización, Gold, marts de Tableau, features y pruebas de calidad funcionan dentro del mismo proyecto.

Evidencia 17 — Commit final y repositorio limpio



Se muestra el commit final de gobernanza, linaje y documentación, seguido del push a origin/main. El repositorio termina sincronizado y con working tree clean. El historial también evidencia commits incrementales reales para los principales bloques de Fase 2.

8. Conclusiones de la Fase 2

- La capa Gold quedó preparada para análisis horario, territorial y multimodal sin leer directamente desde Bronze.
- La cobertura integrada alcanza 15 de 16 zonas analizadas; Santa Catarina Pinula permanece como la única zona sin servicio.
- La seudonimización se realiza antes de Gold y permite mantener consistencia de usuarios sin exponer las llaves originales.
- Tableau quedó conectado a Gold y los dos dashboards responden las preguntas de demanda, cobertura, transbordo y evaluación de MetroRiel.
- La multimodalidad aproximada alcanza 36,827 de 70,380 usuarios (52.33%), y la combinación más frecuente es Transmetro + Transurbano.
- El trazado de MetroRiel cubre algunas zonas de alta demanda, pero Mixco y Zona 7 muestran presión importante fuera del trazado.
- La tabla de features quedó lista para un futuro modelo predictivo, con una fila por usuario y validaciones de calidad específicas.
- La ejecución final cerró con 25 modelos ejecutados y 89 pruebas aprobadas, sin warnings ni errores.

En conjunto, la Fase 2 completa la transición desde un warehouse técnicamente integrado hacia una solución analítica utilizable: la información es trazable, seudonimizada, documentada y disponible tanto para visualización en Tableau como para futuros procesos de ciencia de datos.